- La fase de comprensión de datos de CRISP-DM implica estudiar más de cerca los datos disponibles de minería.
- Este paso es esencial para evitar problemas inesperados durante la siguiente fase (preparación de datos) que suele ser la fase más larga de un proyecto.
- La comprensión de datos implica acceder a los datos y explorarlos con la ayuda de tablas y gráficos que se pueden organizar utilizando diversas herramienta. De esta forma podrá determinar la calidad de los datos y describir los resultados de estos pasos en la documentación del proyecto.

Recopilación de datos iniciales

Los datos provienen de diversos orígenes como:

- ***Datos existentes.*** Esto incluye una amplia variedad de datos, como datos transaccionales, datos de encuestas, registros web, etc. Considere si los datos existentes son suficientes para satisfacer sus necesidades.
- ***Datos adquiridos.*** ¿Su organización utiliza datos adicionales, como datos demográficos? Si no los utiliza, considere si son necesarios.
- ***Datos adicionales.*** Si los orígenes anteriores no satisfacen sus necesidades, es posible que necesite realizar encuestas o realizar seguimientos adicionales para servir de complemento a los almacenes de datos actuales.

Lista de tareas

- ¿Qué atributos (columnas) de la base de datos parecen más prometedores?
- ¿Qué atributos no parecen relevantes y se pueden excluir?
- ¿Existen datos suficientes para obtener conclusiones generales o realizar predicciones precisas?
- ¿Dispone de atributos suficientes para su método de modelado?
- ¿Está fusionando varios orígenes de datos? En caso afirmativo, ¿existen áreas que puedan plantear problemas al fusionar?
- ¿Ha considerado cómo se gestionan los valores perdidos en cada origen de datos?

Fuentes de datos

- **Flat Files**
  Valores separados por comas (CSV), archivos de Excel, archivos de texto (txt), PDF, archivos de registro, etc. Estos también pueden ser archivos específicos del dominio, como archivos XML
  Preprocesar este tipo de datos requerirá un poco más de trabajo

- **Database**
  Expertos en la materia debería poder orientarle en la dirección correcta respecto de las tablas que podría querer consultar.
  Haga muchas preguntas sobre las tablas disponibles.
  A veces, existen tablas de búsqueda adicionales que brindan la clave para comprender los datos en tablas más grandes.
  Además, es posible que pueda enriquecer una tabla con información de otra y, de ese modo, agregar características a su conjunto de datos.

- **Data Warehouse**
  Las tablas Facts y dimensiones son cuidadosamente elaboradas a partir de datos transaccionales sin procesar que brindan la granularidad necesaria para que varias unidades de negocios monitoreen los indicadores clave de rendimiento (KPI) y tomen decisiones.
  A diferencia de las bases de datos tradicionales, los almacenes de datos tienen naturalmente más documentación, ya que requieren que las reglas de negocio se codifiquen en las transformaciones subyacentes que llenan los hechos y las dimensiones. Necesitará un experto que le ayude a señalar algunos lugares de interés en el almacén de datos.

- **Data Lake**
  Un lago de datos es un lugar interesante del que extraer datos. Según su organización, puede estar muy organizado o puede ser un pantano de datos sin documentar.
  Busque un experto y haga muchas preguntas.
  No se sorprenda si encuentra más datos duplicados y conjuntos de datos intermedios.
  Si le dan acceso a un entorno de desarrollo, puede haber tablas, conjuntos de datos y vistas experimentales.

- **API**
  Las interfaces de programación automatizada (API) son excelentes formas de acceder a datos que existen fuera de su organización. Tenga en cuenta que muchas API para uso empresarial tienen términos y condiciones, por lo que debe dedicar tiempo a familiarizarse con ellos, además de costo.

- **Web Scraping**
  En algunos casos, es posible que necesites extraer datos de la web para crear un conjunto de datos. Muchos sitios web tienen API, que generalmente se prefieren a los web Scraping, pero no todos.

Escritura de un informe de recopilación de datos

- Si utiliza el material recopilado en el paso anterior, puede comenzar a escribir el informe de recopilación de datos.
- Una vez completado, el informe se puede añadir al sitio Web del proyecto o distribuir al equipo.
- También se puede combinar con los informes preparados en los pasos siguientes; ***descripción de datos, exploración y verificación de la calidad.***
- Estos informes le guiarán por la fase de preparación de los datos.

Descripción de los datos (Consulte con expertos en la materia (SME))

A continuación se incluyen algunas características clave para describir datos.

- ***Cantidad de datos.*** En la mayoría de técnicas de modelado, los tamaños de datos tienen un equilibrio relacionado. Los grandes conjuntos de datos pueden producir modelos más precisos, pero también pueden aumentar el tiempo de procesamiento.
  Considere utilizar un subconjunto de datos. Cuando tome notas para el informe final, asegúrese de incluir estadísticos de tamaños para todos los conjuntos de datos y recuerde tener en cuenta tanto el número de registros como los campos (atributos) cuando describa los datos.
- ***Tipos de valores.*** Los datos pueden incluir una variedad de formatos, como numérico, categórico (cadena) o Booleano (verdadero/falso). Si presta atención al tipo de valor puede evitar posteriores problemas durante la fase de modelado.
- ***Esquemas de codificación.*** Con frecuencia, los valores de la base de datos son representaciones de características como género o tipo de producto. Por ejemplo, un conjunto de datos puede utilizar M y F para representar masculino y femenino, mientras que otro puede utilizar los valores numéricos 1 y 2. Registre los esquemas incoherentes en el informe de datos.

Teniendo en cuenta este conocimiento, ahora está listo para escribir el informe de descripción de datos y compartir sus descubrimientos con más usuarios.

Consideraciones legales, regulatorias y éticas

Al trabajar con datos, hay algunas cosas que debemos tener en cuenta para asegurarnos de que lo hacemos de manera legal, ética y en cumplimiento de las regulaciones.
Teniendo en cuenta la ética, tenga en cuenta los posibles sesgos que podrían causar problemas. Considere los sesgos introducidos durante la recopilación de datos. Además, evalúe qué sesgos podrían introducirse mediante su método de muestreo de datos.

Escritura de un informe de descripción de datos

Para completar de forma efectiva su proyecto de minería de datos, considere el valor de producir un informe de descripción de datos precisos utilizando las siguientes medidas:

- ***Cantidad de datos***
  - ¿Cuál es el formato de los datos?
  - Identifique el método utilizado para capturar los datos, por ejemplo, Web Scraping.
  - ¿Qué dimensiones tiene la base de datos (en números de filas y columnas)?

- ***Calidad de datos***
  - ¿Incluyen los datos características relativas a la cuestión del procesos de minería?
  - ¿Qué tipos de datos están presentes (simbólicos, numéricos, etc.)?
  - ¿Ha realizado una cálculo básico de los estadísticos de los atributos clave? ¿Qué conocimientos ha proporcionado este proceso en cuestiones comerciales?
  - ¿Puede priorizar los atributos relevantes? En caso negativo, ¿los analistas empresariales pueden proporcionar más conocimientos?
  - Lista de verificación para repasar con el propietario de los datos o el experto en la materia con respecto a con respecto a consideraciones legales, regulatorias y éticas:
    - Preocupaciones sobre la privacidad de los datos
    - Precauciones de seguridad de datos
    - Problemas de precisión de los datos
    - Fuentes de sesgo en los datos
    - Políticas de gobernanza de datos, incluida la retención y eliminación
    - Leyes y reglamentos

VER DIMENSIONES DE LA CALIDAD DE DATOS

Exploración de datos

- Estos análisis ayudan a describir los objetivos de minería de datos generados durante la fase de comprensión comercial.
- También pueden ayudarle a formular hipótesis y dar forma a las tareas de transformación de datos que tienen lugar durante la preparación de los datos.

EDA se guía por las siguientes preguntas:

- ¿Qué tipo de variación ocurre dentro de mis variables?
- ¿Qué tipo de covariación ocurre entre mis variables?

A continuación se presentan algunas ideas sobre qué buscar en diferentes tipos de datos:

- **Datos continuos**
  - ***Resumen de números visualizados como diagramas de caja y bigote***
  - ***Histogramas (Pareto)***
  - ***Diagrama de dispersión del valor a lo largo del tiempo si los datos tienen marca de tiempo***
  - ***Matriz de diagrama de dispersión para comparar pares de variables***
  - ***Coeficiente de correlación (r de Pearson) para probar la correlación lineal entre pares de variables***

- **Datos categóricos**
  - ***Gráfico de barras del número de observaciones por categoría***
  - ***Tablas de frecuencias de dos vías para comparar distribuciones de observaciones entre valores categóricos***
  - ***Prueba de Chi-cuadrado para comprobar la independencia entre variables categóricas***

- **Datos ordinales**
  - ***Correlación de orden de rango de Spearman (r de Spearman)***

Escritura de un informe de exploración de datos

Cuando cree gráficos y ejecute estadísticos sobre los datos disponibles, formule hipótesis acerca de cómo los datos pueden adaptarse a los objetivos técnicos y comerciales.

Lista de tareas

Registre sus descubrimientos para su inclusión en el informe de exploración de datos. Compruebe que responde a las cuestiones siguientes:

- ¿Qué tipo de hipótesis sobre los datos ha formulado?
- ¿Qué atributos parecen ser prometedores de cara a futuros análisis?
- ¿Ha realizado exploraciones que revelen nuevas características de los datos?
- ¿En qué forma han cambiado estas exploraciones su hipótesis inicial?
- ¿Puede identificar subconjuntos concretos de datos para un uso posterior?
- Vuelva a comprobar sus objetivos de minería de datos. ¿Esta exploración ha modificado sus objetivos?

Verificación de calidad de datos

Los datos no suelen ser perfectos. De hecho, la mayoría de los datos contienen errores de codificación, valores perdidos u otro tipo de incoherencias que hacen que los análisis resulten difíciles en algunas ocasiones.
Una forma de evitar posibles problemas es realizar un análisis de calidad de los datos disponibles antes de proceder al modelado.

Las herramientas de informes pueden ayudarle en la búsqueda de los siguientes tipos de problemas:

- Los datos perdidos incluyen valores vacíos o codificados como sin respuesta (como $null$, ? o 999).
- Los errores de datos suelen ser errores tipográficos cometidos al introducir los datos.
- Los errores de mediciones incluyen datos que se introducen correctamente, pero se basan en un esquema de mediciones incorrecto.
- Las incoherencias de codificación suelen incluir unidades no estándar de medida o valores incoherentes, como el uso de M y masculino para expresar el género.

Preguntas que se deben hacer durante los controles de calidad de los datos

- ***¿Cuales son los valores nulos?***
- ***¿Existen "valores de iniciales" u otros datos "basura" que no se ajustan a la definición semántica de las columnas? (por ejemplo, valores de fechas de años futuros, o muy pasados entre otros)***
- ***¿Hay algún valor que no se ajuste a la definición sintáctica de las columnas? (por ejemplo, cadenas en una columna de flotantes)***
- ***¿Hay duplicados?***
- ***¿Hay variación en los datos? (debido al proceso o a la mala calidad de datos)***
- ***¿Hay lagunas en los datos? (por ejemplo, si los datos tienen marcas de tiempo, ¿se muestrean los valores a intervalos regulares)?***

Lista de verificación de datos sucios

- ***Realizar controles de calidad de datos para identificar problemas***
- ***Cuantificar qué cantidad de datos son "sucios"***
- ***Cree un plan y un proceso repetible (por ejemplo, un guión) para eliminar los problemas.***
- ***Actualizar la documentación con detalles de limpieza de datos***
- ***¡Limpia, Limpia, Limpia los datos!***
- ***Validar que los datos erróneos hayan desaparecido***

Escritura de un informe de calidad de datos

En función de los resultados de su exploración y verificación de calidad de datos.

Lista de tareas

Tal y como se ha mencionado anteriormente, existen diferentes tipos de problemas de calidad de datos.
Antes de pasar a la fase siguiente, tenga en cuenta los siguientes problemas de calidad y planifique una solución. Registre todas sus respuestas en el informe de calidad de datos.

- ¿Ha identificado atributos perdidos y campos vacíos? Si es así, ¿los valores perdidos tienen significado?
- ¿Existen faltas de ortografía que puedan causar problemas en futuras fusiones o transformaciones?
- ¿Ha detectado desviaciones para determinar si son "ruido" o fenómenos que merecen un análisis en profundidad?
- ¿Ha realizado una comprobación correcta de los valores? Registre todos los conflictos aparentes (como adolescentes con ingresos muy elevados).
- ¿Ha considerado excluir los datos que no tengan ninguna influencia en sus hipótesis?
- ¿Los datos están almacenados en archivos planos? Si es así, ¿los delimitadores mantienen la coherencia entre los archivos? ¿Contiene cada registro el mismo número de campos?

Antes de preparar los datos para su modelado, considere los siguientes aspectos:

- ¿Cuál es su nivel de comprensión de los datos?
- ¿Ha identificado y accedido correctamente a todos los orígenes de datos? ¿Ha tenido algún problema o restricción de algún tipo?
- ¿Ha identificado atributos clave de los datos disponibles?
- ¿Le han ayudado estos atributos a formular hipótesis?
- ¿Ha detectado el tamaño de todos los orígenes de datos?
- ¿Puede utilizar un subconjunto de datos cuando lo estime conveniente?
- ¿Ha calculado los estadísticos básicos de cada atributo de su interés? ¿Ha obtenido información de interés?
- ¿Ha utilizado gráficos de exploración para obtener atributos clave? ¿Este conocimiento ha reformulado alguna de sus hipótesis?
- ¿Cuáles fueron los problemas de calidad de datos del proyecto? ¿Tiene una planificación para resolver estos problemas?
- ¿Las fases de preparación de los datos son claras? Por ejemplo, ¿sabe qué orígenes de datos debe fusionar y los atributos que debe filtrar o seleccionar?

https://medium.com/@datainsights17/data-quality-in-data-engineering-68d4469f1b30

Dimensiones Comunes de la Calidad de los Datos

Exactitud

Grado en el que los datos representan correctamente entidades “de la vida real”.

La exactitud ***es difícil de medir, a menos que una organización pueda reproducir colecciones de datos o confirmar manualmente la exactitud de los registros.***

La mayoría de las medidas de exactitud ***dependen de la comparación con una fuente de datos que ha sido verificada como exacta***

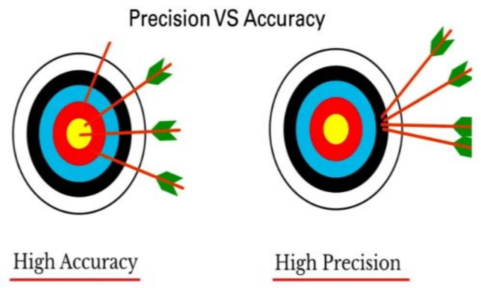

Completitud

Si todos los datos están presentes.

La completitud puede medirse al nivel de conjunto de datos, ***registro o columna.***

¿Contienen los datos todos los registros esperados?

¿Están los registros poblados correctamente?

¿Están las columnas/atributos poblados al nivel esperado?

Consistencia

Puede referir a asegurar que los valores de datos ***sean representados consistentemente dentro de un conjunto de datos y entre conjuntos de datos, y consistentemente asociados entre conjuntos de datos.***

También se puede referir ***al tamaño y composición de los conjuntos de datos entre sistemas a lo largo del tiempo.***

La consistencia puede estar definida ***entre los valores de un conjunto de datos y otro conjunto de atributos en el mismo registro.***

La consistencia puede también ser utilizada para referirse a la consistencia de formato.

Tome en cuenta no confundir consistencia con precisión o correctitud.

Integridad

Integridad de datos (o coherencia) incluye ***ideas asociadas con la completitud, exactitud y consistencia.***

En datos, la integridad se refiere usualmente a la ***integridad referencial*** (consistencia entre objetos de datos vía una clave referencial contenida en ambos objetos) ***o consistencia interna dentro de un conjunto de datos, como que no existan vacíos o partes faltantes.***

Los conjuntos de datos sin integridad son vistos como corruptos, o con pérdida de datos.

Los conjuntos de datos sin integridad referencial tienen “huérfanos” – claves de referencia inválidas, o “duplicados”

Razonabilidad

Pregunta si ***un patrón de datos cumple las expectativas.***

Por ejemplo, si una distribución de ventas a lo largo de un área geográfica tiene sentido basado en lo que es conocido acerca de los clientes de esa área.

La medición de razonabilidad puede tomar diferentes formas. Por ejemplo, la ***razonabilidad puede estar basada en la comparación para generar data referencial, o instancias pasadas de conjuntos de datos similares (por ejemplo, ventas desde el trimestre anterior).***

Oportunidad

Se refiere a varias características de los datos.

Las mediciones de oportunidad ***necesitan ser entendidas en términos de la volatilidad esperada – que tan frecuente los datos cambian y las razones.***

La ***vigencia de los datos es la medida en la cual los valores de datos son la versión más actualizada*** de la información.

Datos relativamente estáticos, por ejemplo, algunos valores de datos referenciales como códigos de países, pueden mantenerse vigentes por largos períodos de tiempo.

Datos volátiles se mantienen vigentes por cortos períodos de tiempo.

Algunos datos, por ejemplo, valores de acciones en páginas web financieras, muestran generalmente mensajes que indican que los valores se tomaron en un momento del tiempo, de tal manera que los consumidores de datos entiendan que existe el riesgo de que los datos hayan cambiado desde que fueron registrados.

Unicidad / Deduplicación

La Unicidad establece que ninguna entidad existe más de una vez en el conjunto de datos.

Confirmar la unicidad de las entidades dentro de un conjunto de datos implica que el valor de la clave se relaciona con cada entidad única, y solamente esta entidad específica, dentro del conjunto de datos.

Validez

La validez se refiere a si los valores de datos son consistentes dentro de un dominio de valores definido.

Un dominio de valores puede ser un conjunto de valores válidos (como en una tabla de referencia), un rango de valores, o un valor que puede ser determinado mediante reglas.

El tipo de dato, formato y precisión de los valores esperados puede ser considerado en la definición del dominio.