Selección de datos

Conceptos básicos sobre preparación de datos

En el "mundo real", los datos son aterradores

La preparación de datos es uno de los aspectos más importantes y con frecuencia que más tiempo exigen en la minería de datos.
De hecho, se estima que la preparación de datos suele llevar el 40-70 % del tiempo y esfuerzo de un proyecto.
Dedicar los esfuerzos adecuados a las primeras fases de comprensión comercial y comprensión de datos puede reducir al mínimo los gastos indirectos relacionados, pero aún deberá dedicar una buena cantidad de esfuerzo para preparar y empaquetar los datos para la minería.
Dependiendo de su organización y sus objetivos, la preparación de datos suele implicar las tareas siguientes:

- ***Fusión de conjuntos y/o registros de datos***
- ***Selección de una muestra de un subconjunto de datos***
- ***Agregación de registros***
- ***Derivación de nuevos atributos***
- ***Clasificación de los datos para el modelado***
- ***Eliminación o sustitución de valores en blanco o perdidos***
- ***División en conjuntos de datos de prueba y entrenamiento***

En 2016, Forbes informó que los profesionales de datos dedican alrededor del 60 % de su tiempo a limpiar datos.
Anaconda realizó el 2022, a una muestra de casi 2000 una encuesta: "¿Cómo invierten su tiempo los científicos de datos?".

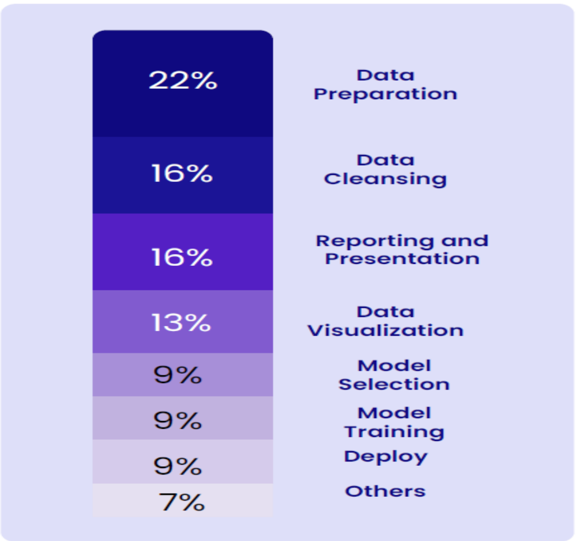

La preparación de datos, con cualquier otro nombre… seguiría siendo preparación de datos.

- Limpieza de datos
- Preprocesamiento de datos
- Manipulación de datos
- Transformación de datos
- Manipulación de datos
- Acondicionamiento de datos
- Proceso de datos
- Integración de datos
- Curación de datos
- Proceso de preparación de datos

¿Por qué la preparación de datos es clave para el éxito?
La preparación de datos es clave para el éxito porque contar con un conjunto de entrenamiento limpio, sólido y bien seleccionado permitirá:

- ***Evite sesgos no deseados en su conjunto de datos debido a datos de entrenamiento mal seleccionados.***
- ***Simplifique el proceso de modelado mediante la inclusión de un diseño de características bien pensado,***
- ***Ayudar en la reproducibilidad a través de un proceso de preparación/limpieza de datos bien documentado.***
- ***Ahorre tiempo en el futuro ya que sus datos estarán bien preparados para futuras iteraciones y análisis.***
- ***Aumente la confianza de las partes interesadas en su análisis porque ha comprendido y tenido en cuenta meticulosamente las brechas en su conjunto de datos.***

Preparamos los datos no solo por necesidad, sino también para garantizar la calidad y la integridad del análisis final.
Recordar el GIGO

En función de la recopilación de datos inicial realizada en la fase anterior, ahora puede comenzar a seleccionar los datos relevantes a sus objetivos de minería de datos. De forma general, existen dos formas de seleccionar datos:

- ***Selección de elementos (filas)*** implica la toma de decisiones como las cuentas, productos o clientes que se van a incluir.
- ***Selección de atributos o características (columnas)*** implica la toma de decisiones sobre el uso de características como la cantidad de las transacciones o los ingresos por hogar.

Inclusión o exclusión de datos

Cuando decide los subconjuntos de datos que se van a incluir o excluir, asegúrese de que documenta los motivos de sus decisiones.

Cuestiones que debe tener en cuenta

- *¿Existe un atributo relacionado con sus objetivos de minería de datos?*
- *¿La calidad de un conjunto o atributo de datos concreto excluye la validez de los resultados?*
- *¿Puede recuperar estos datos?*
- *¿Existen limitaciones acerca del uso de campos concretos como género o raza?*
- *¿Existen decisiones que son diferentes de las hipótesis formuladas en la fase de comprensión de datos? Si es así, asegúrese de que documenta las razones en el informe de proyectos.*

Algunas consideraciones Adicionales

- *Considere estratificar su conjunto de datos en grupos o utilizar un muestreo aleatorio.*
- *Considere, si tiene datos desequilibrados, ¿cómo se asegurará de capturar una cantidad suficiente de todos los grupos de datos relevantes?*
- *Considere, si tiene datos temporales, ¿necesita capturar fragmentos continuos (o, más formalmente, secuencias) de datos?*
- *Asegúrese de documentar y realizar un seguimiento cuidadoso de sus conjuntos de datos para evitar fugas de datos.*

Limpieza de datos

La limpieza o depuración de datos ***transforma los datos para que se ajusten a los estándares de datos y las reglas de dominio.***
La limpieza ***incluye detectar y corregir errores de datos para llevar la calidad de los datos a un nivel aceptable***.
Cuesta dinero e introduce el riesgo de corregir continuamente los datos a través de la limpieza.
Idealmente, la necesidad de limpieza de datos ***debería disminuir con el tiempo, a medida que se resuelven las causas raíz de los problemas de datos.***

La necesidad de limpieza de datos puede mitigarse mediante:

- ***Implementación de controles para evitar errores de entrada de datos.***
- ***Corregir los datos en el sistema fuente.***
- ***Mejora de los procesos de negocio que crean los datos***
- ***En algunas situaciones, puede ser necesario corregir de forma continua, ya que volver a procesar los datos en un sistema intermedio es más barato que cualquier otra alternativa.***

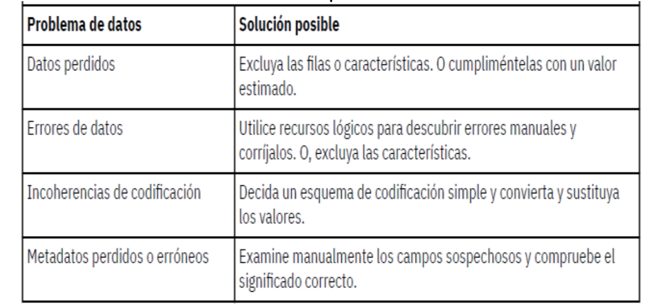

Problema de datos	Solución posible
Datos perdidos	Excluya las filas o características. O cumpliméntelas con un valor estimado.
Errores de datos	Utilice recursos lógicos para descubrir errores manuales y corríjalos. O, excluya las características.
Incoherencias de codificación	Decida un esquema de codificación simple y convierta y sustituya los valores.
Metadatos perdidos o erróneos	Examine manualmente los campos sospechosos y compruebe el significado correcto.

Valores faltantes
Los valores faltantes se pueden manejar de varias maneras, a saber:

- Eliminando las filas con información faltante,
- Imputando los valores faltantes si los datos son continuos o
- Completando el valor con un valor constante.

El patrón de datos faltantes

- ***El patrón univariante*** es poco común y ocurre cuando solo una variable tiene valores faltantes.
- ***El patrón monótono*** de datos faltantes se refiere a cuando un valor faltante implica otro valor faltante.
- ***El patrón no monótono o general*** y la falta de una variable no afecta la falta de otra variable

Mecanismos de datos faltantes

- ***MAR (falta aleatoria):*** Existe una relación sistemática entre la ocurrencia de valores faltantes y los datos observados, pero no los datos faltantes.
  Ejemplo: Las personas con mayores ingresos tienden a no declarar su edad. La falta de edad depende del ingreso (observado).
  Dependencia de la falta: Otra variable observada
  Ejemplo: Riqueza → no responde edad
- ***MCAR (falta completamente aleatoria):*** Como sugiere el nombre, estos valores faltan de forma completamente aleatoria sin ninguna indicación de una razón sistemática para ello.
  Ejemplo: Se pierde un 10% de las edades de los clientes simplemente porque sí, sin relación con ninguna variable.
  Dependencia de la falta: Ninguna
  Ejemplo: Sensor se apagó aleatoriamente
- ***MNAR (falta no aleatoria):*** Existe una razón sistemática para los valores faltantes que se puede modelar y explicar. Por ejemplo, este podría ser un caso en el que los vehículos con un problema de cableado no envían todos los valores de los sensores.
  Ejemplo: Las personas mayores tienden a omitir su edad, precisamente porque son mayores.
  Dependencia de la falta: El propio valor faltante + posibles no observadas
  Ejemplo: Mayor edad → oculta su edad

Valores atípicos

- Los valores atípicos merecen una consideración cuidadosa.

Datos duplicados

- Los datos duplicados pueden producirse debido a errores humanos, errores de software o errores en la secuencia de datos.

Errores o inconsistencias

- Es común que haya errores en los campos de texto de los datos generados por humanos. Es posible que deba corregir errores ortográficos o el uso inconsistente de la puntuación, las mayúsculas.

Datos faltantes o incompletos

- En particular, en el caso de los datos generados por humanos, es posible que surjan problemas en los que los formularios no se completen por completo o las encuestas solo se completen a medias. En el caso de las máquinas, es posible que se presenten casos en los que los sensores fallaron.
- Algunas consideraciones importantes para todos estos problemas son si se va a corregir, eliminar o ignorar el problema y qué tipo de sesgo esto introducirá en el análisis.

Escritura de un informe de limpieza de datos

Registrar sus actividades de limpieza de datos es esencial para registrar las modificaciones de los datos.

Los futuros proyectos de minería de datos se beneficiarán de los detalles del trabajo disponible.

Lista de tareas

Es una excelente idea considerar las siguientes cuestiones cuando genere el informe:

- ¿Qué tipos de ruido se han producido en los datos?
- ¿Qué métodos utiliza para eliminar el ruido? ¿Qué técnicas han demostrado ser eficaces?
- ¿Existen casos o atributos que no se pueden recuperar? Asegúrese de registrar los datos que se han excluido por causas del ruido.

Construcción de nuevos datos (Ingeniería de características)

Con frecuencia, necesitará construir nuevos datos. Por ejemplo, puede ser de gran utilidad crear una nueva columna con la adquisición de una garantía ampliada en cada transacción.

Existen dos formas de construir nuevos datos:

- ***Derivación de atributos*** (columnas o características)
- ***Generación de registros*** (filas)

A continuación, se incluye un resumen de algunas de las diferentes características que se pueden crear:

- ***Características geoespaciales:***
  - Distancia entre dos puntos
  - Altitud
- ***Creando flags***
  - Valores binarios que indican presencia o ausencia de algo
  - Por ejemplo, indicadores “Is_Adult” o “Is_Minor” basados en la columna de edad
  - Codificación one-hot
- ***Creación de valores delta***
  - Si los datos se pueden ordenar de diferentes maneras, puede crear una columna de valor delta como “30_day_delta_weight”.
- ***Agregaciones***
  - Si está agrupando sus datos o realizando un muestreo ascendente, puede crear algunos valores agregados como media, mediana, moda, sesgo, curtosis o número de x en el grupo.
- ***Rolling Values/Window Functions***
  - Con valor temporal, puede calcular una suma o valor media móvil de 1 día o 1 semana
- ***Interacciones***
  - multiplicar/dividir/sumar/restar dos columnas juntas
- ***Transformaciones***
  - Raíz cuadrada
  - valor al cuadrado
  - Inverso
- ***Funciones basadas en texto***
  - Número de palabras
  - Número de palabras únicas
  - Número de caracteres
  - Subjetividad del texto
- ***Cuidado con la maldición de la dimensionalidad***

Derivación de atributos

Se puede utilizar los siguientes nodos de operaciones con campos para derivar nuevos atributos:

- Cree nuevos campos derivados de los actuales mediante un nodo Derivar.
- Cree un campo de marca mediante un nodo Marcar.

Lista de tareas

- Tenga en cuenta los requisitos de datos de modelado cuando derive atributos. ¿El algoritmo de modelado espera un tipo de datos concreto, como datos numéricos? En caso afirmativo, realice las transformaciones necesarias.
- ¿Necesita normalizar los datos antes de proceder con el modelado?
- ¿Se pueden construir los atributos que faltan mediante la agregación, media o inducción?
- En función de sus conocimientos, ¿existen hechos importantes (como la cantidad de tiempo en el sitio Web) que se puedan derivar de los campos existentes?

Integración de datos

No es raro disponer de varios orígenes de datos para el mismo conjunto de cuestiones comerciales. Por ejemplo, puede tener acceso a los datos de un crédito hipotecario, así como a los datos demográficos para el mismo conjunto de clientes. Si estos conjuntos de datos contienen el mismo identificador exclusivo (como el número de seguridad social), puede fusionarlos utilizando este campo de clave.

Existen dos métodos básicos para integrar los datos:

- ***La integración de datos*** implica unir dos conjuntos de datos con registros similares, pero con atributos diferentes. Los datos se fusionan utilizando el mismo identificador clave en cada registro (como el ID de usuario). Los datos resultantes aumentan las columnas o las características.
- ***La adición de datos*** implica integrar dos o más conjuntos de datos con atributos similares, pero con registros diferentes. Los datos se integran en función de los campos similares (como el nombre de producto o la longitud del contrato).

Tareas de integración

La interpretación de los datos puede ser un proceso complejo si no ha invertido la cantidad de tiempo adecuada en el desarrollo y comprensión de los datos. Dedique algún tiempo para reflexionar acerca de los elementos y atributos que parecen más relevantes a los objetivos de minería de datos y a continuación comience a integrar los datos.

Lista de tareas

- Considere guardar los resultados antes de proceder al proceso de modelado.
- Tras la integración, los datos se pueden simplificar agregando valores. La agregación implica que los nuevos valores se calcularán resumiendo la información de diferentes registros y/o tablas.
- Es posible que tenga que generar nuevos registros (como el descuento medio de varios años de devoluciones de impuestos combinadas).

Formato de datos

Como paso final antes de la generación del modelo, es muy útil comprobar si algunas técnicas requieren aplicar un formato concreto o la clasificación de los datos. Por ejemplo, no es extraño que un algoritmo de secuencia requiera que los datos estén clasificados de forma previa antes de ejecutar el modelo. Incluso si el modelo puede ejecutar la clasificación de forma automática, puede ahorrar tiempo si utiliza un nodo
Ordenar antes del modelado.

Lista de tareas

Considere las siguientes cuestiones cuando aplique formato a los datos:

- ¿Qué modelos ha planeado utilizar?
- ¿Estos modelos requieren un formato de datos o una clasificación concreta?

Antes de construir modelos, asegúrese de contestar las siguientes cuestiones.

- ¿Puede acceder a todos los datos?
- En función de los procesos de exploración y comprensión iniciales, ¿ha podido seleccionar los subconjuntos relevantes de datos?
- ¿Ha limpiado los datos de forma efectiva o eliminado los elementos que no se pueden guardar? Registre todas las decisiones en el informe final.
- ¿Los diferentes conjuntos de datos se integran correctamente? ¿Existen problemas de fusión que se deben mencionar?
- ¿Conoce las herramientas de modelado necesarias que ha planificado utilizar?
- ¿Existen problemas de formato que deba solucionar antes del proceso de modelado? Se incluyen problemas de formato y tareas que pueden reducir el tiempo de modelado.

Si puede responder las cuestiones anteriores, está listo para pasar al proceso clave de modelado de minería de datos.