Universidad Nacional Mayor de San Marcos

Facultad de Ingeniería de Sistemas e Informática

MINERÍA DE DATOS



Predicción del incumplimiento crediticio y estabilidad temporal

Caso: Home Credit - Credit Risk Model Stability

AUTORES

Torres Lezama Mathias James

Cuenca Echevarria Andre Alexander

Salcedo Alfaro Nick Emanuel

Davalos Velazco Gabriel Mathias

Villavicencio Davila Giancarlo

PROFESOR

PEDRO MARTIN LEZAMA GONZALES

Lima, Perú

2026

Índice

1 Entendimiento empresarial..... 3
1.1 Determinar los objetivos comerciales..... 3
1.2 Evaluar la situación..... 4
1.3 Determinar los objetivos de la minería de datos..... 6
1.4 Producir el plan del proyecto..... 7
2 Comprensión de los datos..... 8
2.1 Recopilar datos iniciales..... 8
2.2 Describir datos..... 9
2.3 Explorar datos..... 10
2.4 Verificar la calidad de los datos..... 11
3 Preparación de datos..... 14
3.1 Seleccionar datos..... 14
3.2 Datos limpios..... 17
3.3 Datos de construcción..... 18
3.4 Integrar datos..... 20
3.5 Formatear datos..... 21

1 Entendimiento empresarial

1.1 Determinar los objetivos comerciales

En el crédito de consumo dirigido a personas con historial crediticio limitado o inexistente, un modelo de riesgo puede perder capacidad predictiva con el tiempo si cambian el perfil de los solicitantes, su comportamiento de pago o el contexto. Esa pérdida puede llevar a subestimar el riesgo de incumplimiento o a sobreestimar el de clientes solventes.

El proyecto estudia este problema en un entorno académico con el dataset Home Credit – Credit Risk Model Stability de Kaggle, que reúne más de 30 tablas de distintas granularidades y permite analizar el desempeño por semana de observación. No representa una evaluación ni una solución desplegada en una entidad financiera real.

Tabla 2 lista los cinco objetivos de negocio (ON). El ON5 no figura entre los cuatro objetivos oficiales del caso de negocio; se justifica por la sección de eficiencia (Efficiency) del caso de negocio y por la Resolución SBS N° 00053-2023.

Tabla 2. Objetivos de negocio.

ID	Objetivo de negocio
ON1	Estimar el riesgo de incumplimiento de cada solicitante para respaldar la decisión de crédito.
ON2	Lograr que el criterio de riesgo no pierda validez con el paso del tiempo.
ON3	Comprender qué factores explican el riesgo.
ON4	No rechazar por error a solicitantes solventes.
ON5	Saber a tiempo cuándo el criterio de riesgo deja de ser confiable.

Beneficio esperado. En un escenario hipotético de adopción financiera, una estimación de riesgo estable podría aportar evidencia para priorizar la revisión de solicitudes y monitorear la pérdida de validez de un modelo. En este proyecto el beneficio directo es experimental: estudiar el problema, documentar resultados reproducibles y construir un prototipo demostrativo. No se tomarán decisiones crediticias reales.

Criterios de éxito.

- Completar las seis fases de CRISP-DM y documentar el proceso de forma reproducible.
- Obtener al menos un modelo funcional y comparar modelos de clasificación.
- Evaluar el desempeño predictivo y su variación temporal por WEEK_NUM, incluida la validación fuera de tiempo.
- Entregar el conjunto de datos preparado para modelado, la evaluación comparativa, el análisis de estabilidad, el informe y la presentación final.

- Construir un prototipo funcional de demostración en un entorno controlado, sin conexión a sistemas reales.

1.2 Evaluar la situación

Alcance. Integrar las tablas disponibles del dataset respetando sus granularidades, preparar datos y características, entrenar y comparar modelos de clasificación y evaluar su desempeño predictivo y su estabilidad temporal. La incorporación de fuentes se hace de forma controlada durante las fases de comprensión y preparación de datos.

Fuera de alcance. No se integrará el modelo con sistemas financieros reales, no se automatizarán decisiones de crédito y no se usarán datos externos a los distribuidos para la competición.

Recursos. El proyecto usa el tiempo y la capacidad de cómputo del equipo, sin presupuesto monetario. El entorno contempla Python 3.11 o superior y las bibliotecas polars, pyarrow, numpy, scikit-learn y TensorFlow. La selección de modelos se basará en su desempeño y estabilidad temporal.

Responsables. Los roles del equipo figuran en Tabla 3.

Tabla 3. Responsabilidades del equipo.

Integrante	Responsabilidad
Pedro Lezama Gonzales	Patrocinador; valida entregables y resuelve conflictos escalados.
Nick Emanuel Salcedo Alfaro	Líder del proyecto; coordina cronograma y tareas, contacto con patrocinador y consolidación del informe.
Mathias James Torres Lezama	Comprensión y preparación de datos; tablas de solicitud actual y bureau.
Andre Alexander Cuenca Echevarria	Modelado y prototipo demostrativo (API o dashboard).
Gabriel Mathias Davalos Velazco	Comprensión y preparación de datos; solicitudes previas, depósitos y tarjetas.
Giancarlo Villavicencio Davila	Evaluación comparativa y estabilidad temporal con validación OOT por WEEK_NUM.

Riesgos y contingencias. Tabla 4 conserva el estado que registra el plan del proyecto: los cuatro riesgos figuran como pendientes porque ninguno se dio por cerrado formalmente. La última columna indica qué aportaron las fases 2 y 3, solo para los dos riesgos que esas fases abordaron.

Tabla 4. Riesgos del proyecto, estado registrado y avance de las fases 2 y 3.

Riesgo	Mitigación acordada	Estado	Avance de las fases 2 y 3
Alto volumen y complejidad de datos	Procesamiento incremental, agregaciones por fuente y control de memoria	Pendiente	La familia más grande (188 298 452 filas) se perfiló en 11 bloques con un solo hilo, y la preparación completa se reconstruyó desde cero en 101,7 s. El riesgo se abordó; el estado formal sigue sin actualizarse.
Fuga de información	Validación OOT y revisión de disponibilidad temporal	Pendiente	Se aplicó un filtro temporal a todas las fuentes con fecha y se detectó y corrigió una fuga en los indicadores de productos y registros (sección 3.4). No se demuestra ausencia total de fuga.
Sobreajuste	Regularización, early stopping y evaluación por semana	Pendiente	Sin avance: corresponde a la fase 4.
Inestabilidad temporal	Seguimiento de Gini/AUC por WEEK_NUM	Pendiente	Sin avance sobre el modelo. La fase 2 midió que la tasa de incumplimiento semanal no es estable (sección 2.3).

1.3 Determinar los objetivos de la minería de datos

Cada objetivo de negocio se traduce en exactamente un objetivo de minería de datos (OM) con su medida de éxito (Tabla 5). El OM2 evalúa en tiempo de diseño, mientras que el OM5 decide en operación. La Gini Stability sigue siendo la métrica de la competición; el Gini/AUC global (OM1) no la reemplaza.

Tabla 5. Trazabilidad entre objetivos de negocio y de minería de datos.

ON	OM	Objetivo de minería de datos	Medida de éxito
ON1	OM1	Clasificación binaria: score de probabilidad de incumplimiento entre 0 y 1 para cada case_id.	Gini/AUC global en validación OOT.
ON2	OM2	Validación fuera de tiempo (OOT) por WEEK_NUM para verificar que el desempeño se mantiene.	Gini Stability (métrica de la competición).

ON	OM	Objetivo de minería de datos	Medida de éxito
ON3	OM3	Identificar las variables o grupos de variables más influyentes.	Ranking de importancia reproducible.
ON4	OM4	Optimizar el umbral de decisión y evaluar falsos positivos, precisión, recall y calibración.	Tasa de falsos positivos (FPR) a recall fijo. Punto de operación (por ejemplo, TPR = 0,80): supuesto por acordar.
ON5	OM5	Regla de alerta sobre el Gini semanal y su tendencia.	Detecta la degradación en las semanas OOT. Tamaño de la caída y número de semanas: supuesto por acordar.

Métrica. Para el análisis temporal se calcula el Gini por WEEK_NUM, y sobre esos valores se ajusta una regresión lineal gini = a × WEEK_NUM + b. La métrica final penaliza el deterioro temporal y la variabilidad de los resultados:

$$Gini\ semanal = 2 \times ROC\text{-}AUC\ semanal - 1$$

$$Gini\ Stability = media(Gini\ semanal) + 88 \times min(0, a) - 0{,}5 \times desviación\ estándar(residuos)$$

Un valor más alto indica mejor poder predictivo, mayor estabilidad en el tiempo y menor variabilidad. **Criterio de selección.** El modelo final se elegirá por el equilibrio entre desempeño global, estabilidad temporal, interpretabilidad, coste computacional y reproducibilidad.

1.4 Producir el plan del proyecto

El plan fija una fecha límite por fase (Tabla 6). El cronograma se ajustó para establecer el 05/12/2026 como fecha límite común para todas las fases del proyecto.

Tabla 6. Plan del proyecto por fase.

Fase	Fecha límite	Producto esperado
Comprensión del negocio	05/12/2026	Objetivos, alcance y plan definidos.
Comprensión de datos	05/12/2026	Inventario, exploración y calidad de datos.
Preparación de datos	05/12/2026	Conjunto de datos preparado para modelado.
Modelado	05/12/2026	Modelos comparados con validación temporal.

Fase	Fecha límite	Producto esperado
Evaluación	05/12/2026	Desempeño comparativo y estabilidad analizados.
Implementación y presentación final	05/12/2026	Prototipo demostrativo, informe y presentación.

2 Comprensión de los datos

2.1 Recopilar datos iniciales

Los datos proceden de la competición Home Credit – Credit Risk Model Stability y se almacenan localmente en formato Parquet. Se dispone de las definiciones de variables, del formato de predicción, de los archivos de entrenamiento y de los de prueba. La lectura de datos, el perfilador y la métrica base se implementaron en módulos comunes del proyecto, verificados con 81 pruebas automáticas al cerrar la fase.

Se inspeccionaron los metadatos de 68 archivos Parquet: 32 de entrenamiento y 36 de prueba, organizados en 17 familias lógicas. Cuatro familias se dividen en varios fragmentos físicos (Figura 1), lo que explica la diferencia entre 32 y 36 archivos y no constituye una diferencia de esquema. Tabla 7 resume la estructura de cada familia.

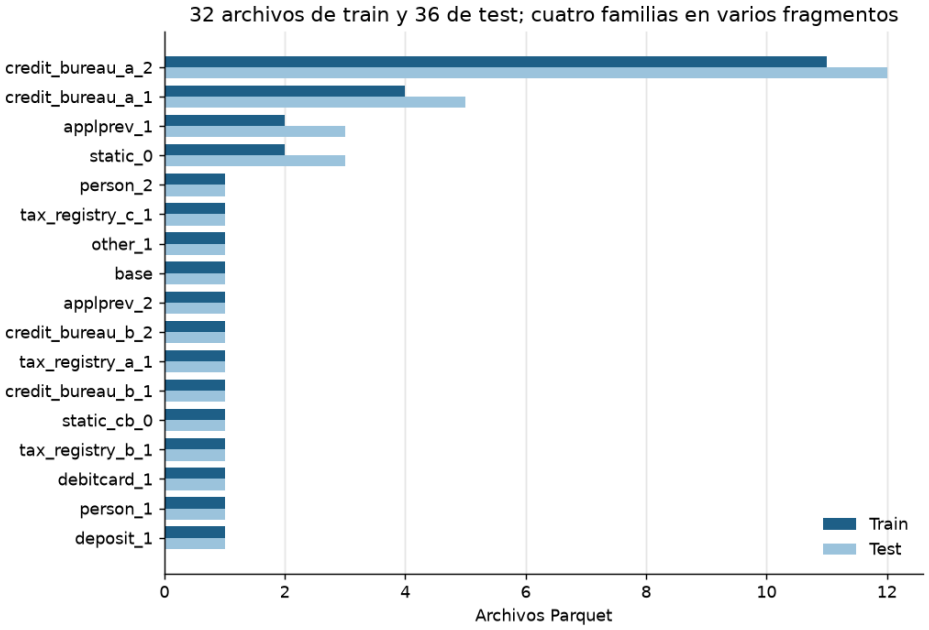


Figura 1. Archivos Parquet por familia y partición. Fuente: inventario de metadatos Parquet.

Tabla 7. Inventario de familias de tablas (entrenamiento).

Familia	Archivos train / test	Filas por archivo en train	Columnas	Granularidad inferida
base	1 / 1	1 526 659	5 / 4	Una fila por caso
applprev_1	2 / 3	2 638 295–3 887 684	41	Varias filas por caso
applprev_2	1 / 1	14 075 487	6	Registros anidados por caso
credit_bureau_a_1	4 / 5	2 079 323–6 009 192	79	Registros de bureau por caso
credit_bureau_a_2	11 / 12	4 386 062–33 053 760	19	Registros anidados de bureau
credit_bureau_b_1	1 / 1	85 791	45	Registros de bureau por caso
credit_bureau_b_2	1 / 1	1 286 755	6	Pagos anidados de bureau
person_1, person_2	2 / 2	1 643 410–2 973 991	11–37	Personas relacionadas con el caso
static_0	2 / 3	522 902–1 003 757	168	Una fila por caso
static_cb_0	1 / 1	1 500 476	53	Una fila por caso, bureau
debitcard_1	1 / 1	157 302	6	Tarjetas por caso
deposit_1	1 / 1	145 086	5	Depósitos por caso
other_1	1 / 1	51 109	7	Otros productos por caso
tax_registry_[a-c]_1	3 / 3	1 107 933–3 343 800	5	Registros fiscales por caso

Los archivos de prueba disponibles contienen 10 filas cada uno, salvo test_tax_registry_c_1.parquet, que está vacío. Sirven para revisar compatibilidad de esquema, no para representar el volumen ni la distribución del conjunto de prueba completo.

2.2 Describir datos

Tabla base. train_base tiene 1 526 659 filas y 5 columnas (case_id, date_decision, MONTH, WEEK_NUM y target), sin nulos, con 0 claves repetidas y 0 filas duplicadas exactas. Cada fila es un caso de crédito. date_decision va del 2019-01-01 al 2020-10-05, y MONTH y WEEK_NUM coinciden con ella en todas las filas. La tabla base no contiene predictores propios: solo clave, campos temporales y objetivo.

Variable objetivo. target es binario: 1 478 665 casos de clase 0 (96,86 %) y 47 994 de clase 1 (3,14 %), un desbalance marcado. WEEK_NUM va de 0 a 91 y MONTH de 201901 a 202010.

Catálogo de variables. Se cruzaron los esquemas de las 17 familias con las 465 entradas del diccionario oficial. El resultado son 503 apariciones de columnas por familia y 471 nombres distintos, de los cuales 464 tienen descripción oficial. Los siete sin entrada son campos estructurales o de la tabla base, de modo que no hay predictores de negocio sin definición (Tabla 8). Las claves y los campos temporales se reservan para trazabilidad y validación; el resto requiere comprobar disponibilidad temporal y definir una agregación acorde con su granularidad antes de entrar al modelo.

Tabla 8. Columnas por grupo de familias y definición oficial.

Grupo de familias	Apariciones de columnas	Con definición oficial
Base y estáticas (base, static_0, static_cb_0)	226	219
Solicitudes previas (applprev_1, applprev_2)	47	42
Bureau de crédito (cuatro familias)	149	139
Personas (person_1, person_2)	48	43
Productos y registros fiscales (seis familias)	33	21

2.3 Explorar datos

La tabla base no contiene predictores, por lo que no corresponde extraer asociaciones entre predictores y target en esta etapa. El análisis se concentró en la dimensión temporal.

Análisis temporal. Se observaron las 92 semanas (WEEK_NUM 0 a 91) sin semanas ausentes ni etiquetas nulas. La cobertura semanal no es uniforme: la mediana es 17 088,5 casos, con un mínimo de 825 en la semana 68 y un máximo de 35 920 en la semana 51. La tasa de incumplimiento semanal tampoco es estable: su mediana es 2,79 %, con un mínimo de 1,77 % en la semana 86 y un máximo de 5,21 % en la semana 62 (Figura 2). Por bloques de diez semanas, la tasa sube de 2,68 % en las semanas 0 a 9 a 4,28 % en las semanas 60 a 69 y baja a 2,03 % en las semanas 80 a 89. Esta variación justifica una validación temporal, porque una partición aleatoria mezclaría regímenes con tasas base distintas.

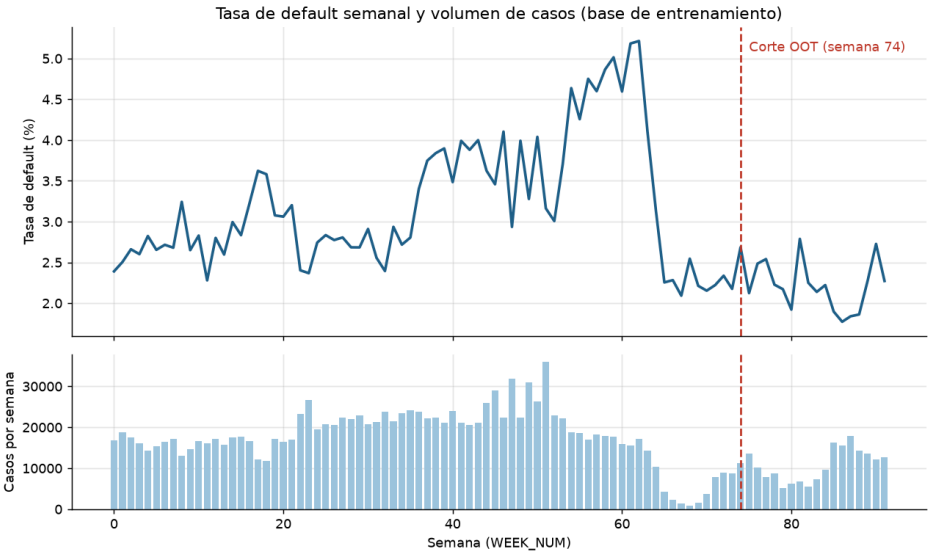


Figura 2. Tasa de default semanal y casos por semana en la base de entrenamiento, con el corte OOT en la semana 74.

Corte fuera de tiempo. Se fijó WEEK_NUM = 74 como corte primario: reserva aproximadamente el último 20 % de las semanas observadas. El entrenamiento (semanas 0 a 73) contiene 1 332 001 casos y 43 734 positivos (3,2833 %). El conjunto OOT (semanas 74 a 91) contiene 194 658 casos y 4 260 positivos (2,1885 %), equivalentes a 18 semanas, 12,75 % de los casos y 8,88 % de los positivos. WEEK_NUM no se usa como predictor y toda transformación se ajusta solo con semanas menores que 74.

Métrica oficial. Se revisó la definición oficial de la competición (consultada el 2026-10-12). Se calcula un Gini independiente por cada semana observada y luego se agregan sin ponderar por cantidad de casos, según la fórmula de la sección 1.3. La implementación rechaza el cálculo si alguna semana tiene una sola clase, si hay nulos o valores no finitos, o si el objetivo no pertenece a {0, 1}. Como diagnósticos se conservan el Gini/AUC global, el Gini por semana con su soporte, PR AUC, log loss y Brier score; ninguno reemplaza la Gini Stability OOT como criterio de selección.

Hipótesis. La tabla base no permite formular hipótesis sobre predictores. Los perfiles de las demás fuentes sugieren revisar en fases posteriores la ausencia estructural, los historiales de mora y pagos, los importes, las categorías casi constantes y las variables de alta cardinalidad. Son líneas de revisión, no hallazgos causales.

2.4 Verificar la calidad de los datos

Esta sección resume los hallazgos de calidad de las 17 familias de entrenamiento, perfiladas sin combinar tablas ni imputar o eliminar valores.

Base. Los dos hallazgos de la tabla base son que date_decision está almacenada como texto aunque el 100 % de sus valores se interpreta como fecha, y el desbalance de clases (3,14 % de positivos), que obliga a elegir métricas adecuadas y a respetar el protocolo OOT.

Ausencia de valores. Es heterogénea entre fuentes (Figura 3). credit_bureau_a_1 tiene 65 de 79 columnas con al menos 50 % de nulos, static_cb_0 36 de 53, static_0 49 de 168 y

person_1 15 de 37. Los máximos alcanzan 99,97 % en clientscnt_136L (static_0). La imputación debe conservar indicadores de ausencia y evaluarse por fuente; no se eliminan columnas solo por este perfil.

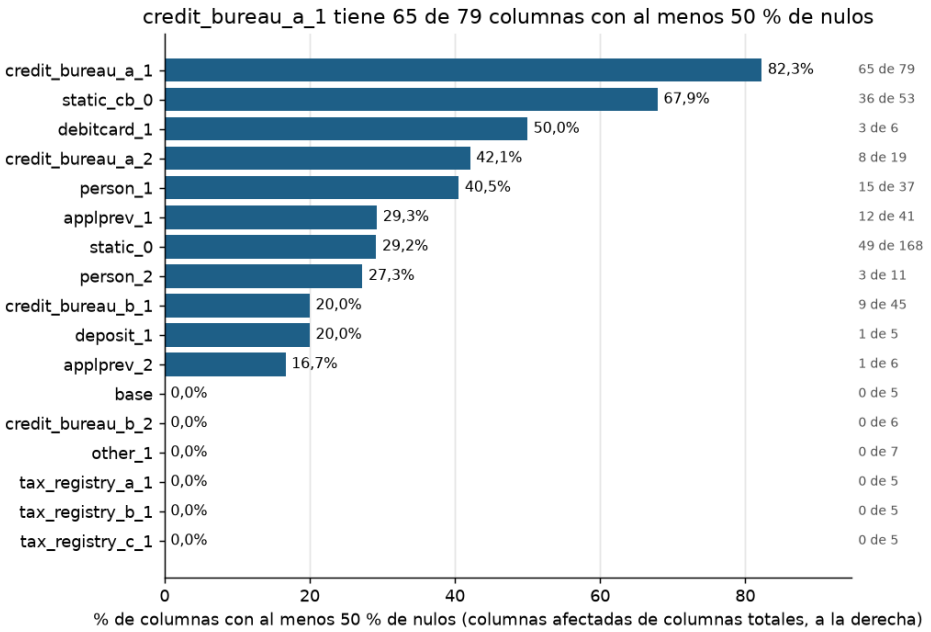


Figura 3. Porcentaje de columnas con al menos 50 % de nulos por familia. A la derecha, columnas afectadas de columnas totales. Fuente: resumen del catálogo de calidad.

Categorías y rangos. Hay 32 columnas cuya categoría dominante representa al menos 95 % de los valores no nulos, y solo dos columnas constantes globales (num_group1 de other_1 y deferredmnthsnum_166L de static_0). Aparecen rangos que requieren interpretación y no corrección automática: garantías de hasta 98 780 millones, máximos de mora superiores a 185 millones en credit_bureau_b_2 e importes negativos en depósitos, tarjetas y saldos. Un valor negativo puede representar días antes del vencimiento o movimientos contables, por lo que se conserva hasta validar su semántica.

Integridad de claves. La unicidad se verificó exactamente en las 17 familias: case_id no tiene nulos, las claves candidatas (case_id, case_id + num_group1 o case_id + num_group1 + num_group2) no tienen duplicados y no hay filas huérfanas respecto de la base. Las fuentes de profundidad 1 y 2 contienen varias observaciones por caso y deben agregarse antes de unirse.

Riesgo de multiplicación en joins. Un left join directo de una fuente 1:N replica los casos cubiertos. Tabla 9 y Figura 4 muestran las familias con mayor expansión; credit_bureau_a_2 pasaría de 1 526 659 a 188 439 823 filas. Unir dos fuentes 1:N entre sí por case_id produce el producto de sus filas (2 × 3 = 6, no 5). Por ello, cada familia se filtra temporalmente y se agrega por separado antes de unirse a la base.

Tabla 9. Filas tras un left join directo con la base, por familia (las siete de mayor expansión).

Familia	Filas tras join directo	Factor medio sobre la base	Máximo de filas por caso
credit_bureau_a_2	188 439 823	123,43×	9 404
credit_bureau_a_1	16 080 923	10,53×	529
applprev_2	14 380 624	9,42×	79
applprev_1	6 831 116	4,47×	20
tax_registry_c_1	4 388 194	2,87×	121
tax_registry_a_1	4 344 495	2,85×	99
credit_bureau_b_2	2 776 967	1,82×	301

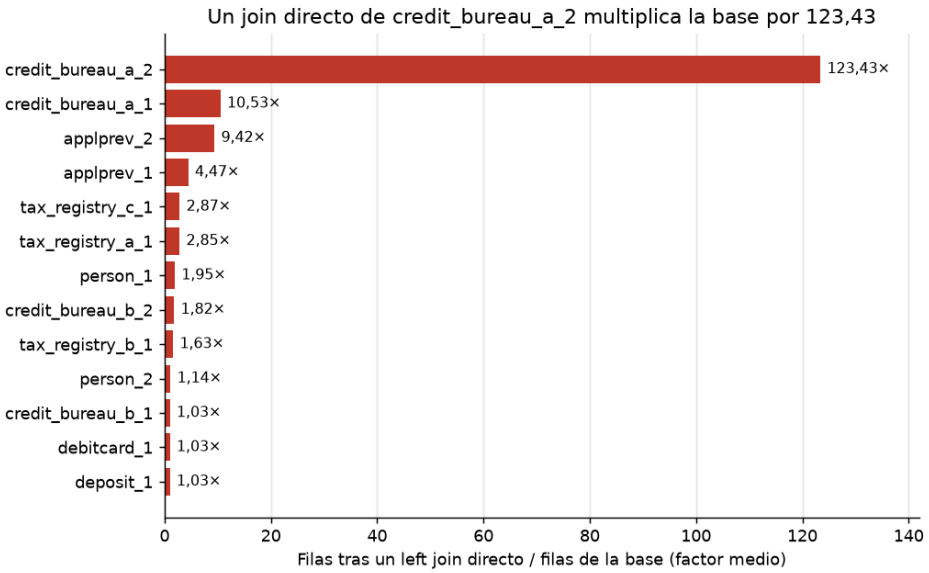


Figura 4. Factor medio de multiplicación de filas en un left join directo con la base, por familia. Fuente: análisis de riesgo de integración.

Disponibilidad temporal y fuga. La definición oficial y el nombre de una columna confirman su semántica, no el instante real de extracción, por lo que ningún predictor se declara seguro solo por su nombre. Las fuentes con fechas explícitas exigen que la fecha del evento sea menor o igual que date_decision antes de agregar. Los estados, aprobaciones, deuda actual, pagos y mora pueden haberse actualizado después de la decisión y se excluyen hasta demostrar una instantánea válida. Las claves y los cuasi-identificadores (nombres, empleadores, direcciones, distritos, códigos postales y teléfonos) no entran como predictores.

Compatibilidad entre entrenamiento y prueba. Las 17 familias están presentes en ambos conjuntos y las 503 apariciones de columnas coinciden por nombre salvo target, que solo

existe en entrenamiento. De las 503 columnas, 428 tienen tipo físico idéntico, 53 son convertibles explícitamente, 17 aparecen como nulas en algún fragmento de prueba, cuatro fechas requieren validación con una prueba real y una es target. De 112 columnas categóricas o booleanas revisadas, 101 tienen todos los valores de prueba confirmados en entrenamiento y tres contienen cuatro categorías no vistas. Hay 80 observaciones fuera del rango de entrenamiento en nueve columnas, esperables en un corte temporal futuro. Estas diferencias no son errores confirmados; la muestra de prueba es demasiado pequeña para estimar frecuencias o deriva.

3 Preparación de datos

La preparación produjo una matriz de modelado con una fila por caso para entrenamiento, OOT y prueba. Los controles verifican paridad de características y tipos entre conjuntos (salvo target en prueba) y todas las fuentes con fecha se filtran contra date_decision. Eso no demuestra por sí solo la ausencia total de fuga. El capítulo se cerró el 13/10/2026 tras una reconstrucción completa desde los Parquet originales.

3.1 Seleccionar datos

Universo de casos. La base de cada conjunto define sus casos. Las fuentes con varias filas por caso se agregan a una fila por case_id antes de unirlas, y toda familia con fecha de disponibilidad aplica un filtro temporal. Una columna entra como predictor solo si cumple cinco condiciones:

1. No es clave, cuasi-identificador ni atributo sensible (sexo y género quedan fuera).
2. Su disponibilidad al decidir está justificada por una regla temporal y no por su nombre.
3. No es una fecha con aspecto de calendario o proyección.
4. Tiene al menos 5 % de cobertura en su tabla fuente.
5. Pasa un filtro empírico de fuga calculado solo con entrenamiento: Gini univariado y del indicador de ausencia no mayores a 0,5 en valor absoluto, sin cambio de signo entre tres bloques de semanas. Las ocho columnas de texto se aprobaron por regla, sin medición.

Fuentes incluidas. En este primer corte solo las solicitudes previas y las personas aportan predictores; el resto de familias aporta indicadores de cobertura (número de registros y presencia de la fuente), porque la revisión de columnas no encontró evidencia temporal suficiente para ellas (Tabla 10, Figura 5). Las 94 columnas predictoras salen de 35 columnas fuente aprobadas: 19 de applprev_1 y 16 de person_1. El ancla es la fecha de referencia de cada fuente de bureau, y las tablas de profundidad 2 (hijas) se vinculan a una fila de profundidad 1 (padre).

Tabla 10. Aporte, regla temporal y cobertura por familia.

Familia	Aporta	Predictores	Regla temporal	Cobertura train / OOT
applprev	Importes, plazos, categorías, indicadores y recencias	61	Fila válida si la creación es anterior o igual a la decisión; el hijo solo con padre válido	78,2 % / 85,2 %
person	Atributos de la persona principal, edad, antigüedad laboral	33	Atributos de la solicitud actual; fechas internas hasta la decisión	100 % / 100 %
static_0	Cobertura	0	No aplica	100 % / 100 %
static_cb_0	Cobertura	0	No aplica	98,1 % / 99,9 %
credit_bureau_a	Cobertura	0	Ancla anterior o igual a la decisión; credit_bureau_a_2 se omite sin ancla aprobada	71,0 % / 87,6 %
credit_bureau_b	Cobertura	0	Ancla anterior o igual a la decisión; hijo con padre válido	0,4 % / 0,9 %
debitcard_1, deposit_1	Cobertura	0	Fecha de apertura anterior o igual a la decisión; fecha nula descartada	6,7 % / 8,1 %
tax_registry_b_1	Cobertura	0	Fecha de deducción anterior o igual a la decisión	1,8 % / 64,7 %
tax_registry_c_1	Cobertura	0	Fecha de procesamiento anterior o igual a la decisión	30,3 % / 0 %

Familia	Aporta	Predictores	Regla temporal	Cobertura train / OOT
tax_registry_a_1, other_1	Nada: constantes en train, se descartan	0	Todas las filas posteriores a la decisión o sin fecha	0 % / 0 %

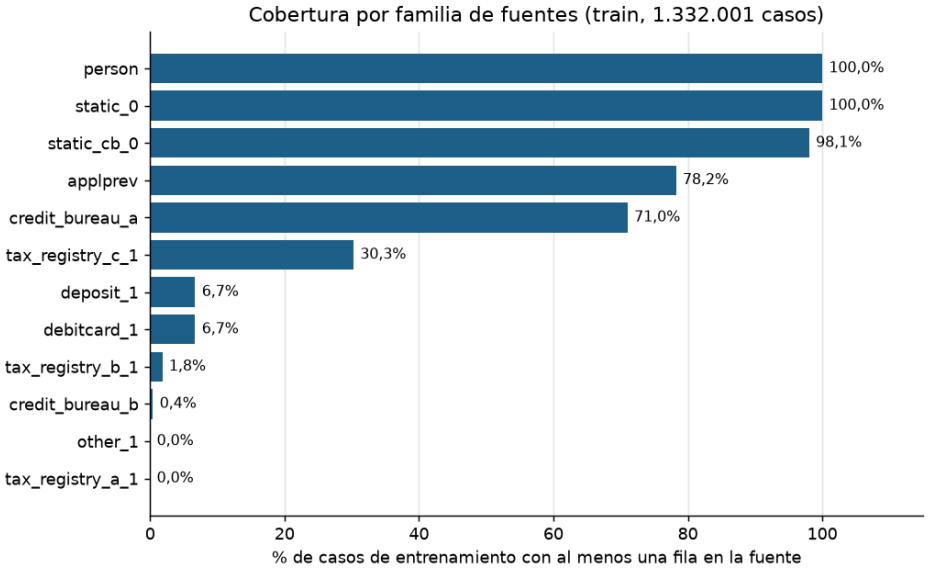


Figura 5. Cobertura por familia de fuentes: porcentaje de casos de entrenamiento con al menos una fila en la fuente (1 332 001 casos).

Fuentes excluidas. Excluida es una decisión definitiva en el primer corte; bloqueada es una exclusión preventiva que puede revisarse con evidencia de disponibilidad al decidir (Tabla 11). Se excluyen claves, índices y fechas de partición, cuasi-identificadores, los atributos sensibles gender_992L y sex_738L, riskassesment_302T (describe una probabilidad de incumplimiento futura) y los estados, mora, pagos, deuda y motivos de rechazo que pudieron actualizarse después de la decisión. credit_bureau_a_2 no entra porque su única referencia es año y mes de pago y no hay ancla temporal aprobada.

Tabla 11. Columnas por resultado de la selección.

Selección	Columnas	Excluidas	Bloqueadas	Aplazadas	Aprobadas
Profundidad 0 (base y estáticas)	226	31	195	0	0
Solicitudes y personas	95	34	21	5	35
Bureau	149	23	126	0	0
Productos y registros	33	15	18	0	0

Partición temporal. Tabla 12 muestra los conjuntos resultantes (Figura 6). Entrenamiento y OOT suman 1 526 659 casos sin solapamiento. La prueba no tiene target y se usa para comprobar compatibilidad de esquema.

Tabla 12. Partición temporal de los casos.

Conjunto	Semanas	Casos	Positivos	Tasa
Entrenamiento	WEEK_NUM < 74	1 332 001	43 734	3,28 %
OOT	WEEK_NUM ≥ 74	194 658	4 260	2,19 %
Prueba	Muestra local de Kaggle	10	—	—

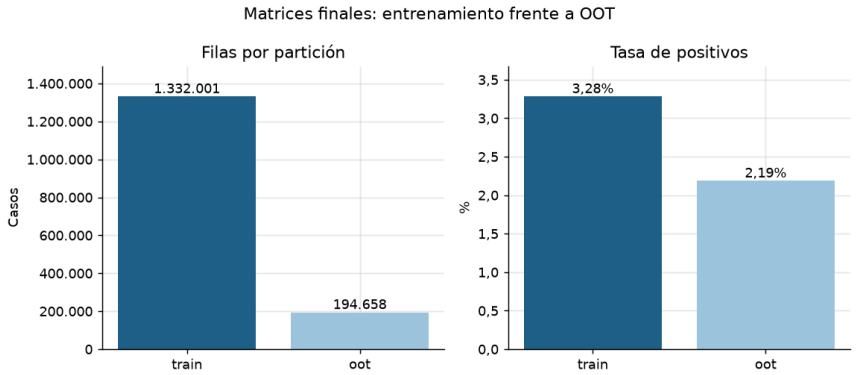


Figura 6. Filas por conjunto y tasa de positivos en entrenamiento y OOT.

3.2 Datos limpios

Tabla 13 resume las reglas de limpieza. Todos los parámetros (medianas, vocabularios, rangos) se aprenden solo con entrenamiento. Los conteos de filas excluidas por la regla de disponibilidad temporal se muestran en Figura 7 y se detallan por regla en la sección 3.3.

Tabla 13. Reglas de limpieza aplicadas.

Problema	Regla aplicada	Justificación
Valores faltantes	Las numéricas se imputan con la mediana de entrenamiento y llevan un indicador de ausencia; en las categóricas el nulo pasa a __missing__.	La ausencia puede ser señal; los parámetros solo se aprenden con entrenamiento.
Valores atípicos	Un valor fuera del rango de entrenamiento genera un aviso, sin recorte. Ninguna columna tiene recorte aprobado.	Un rango nuevo en un periodo futuro es esperable y no es un error.

Problema	Regla aplicada	Justificación
Tipos y codificación	Coerción estricta al tipo lógico. Un valor no convertible o infinito es un error.	Nunca se convierte un valor inválido en nulo en silencio.
Categorías raras o nuevas	Las de frecuencia menor a 1 % en entrenamiento, o no vistas, pasan a __UNKNOWN__, con vocabulario congelado.	OOT y prueba no amplían el vocabulario.
Eventos posteriores a la decisión	La fila se excluye (solicitudes previas, anclas de bureau, fechas de productos y registros) o el campo se anula (fechas internas). También se descartan filas sin ancla o con padre inválido.	Los conteos se registran por regla y no entran como predictores.
Claves inválidas	Una clave nula o repetida es un error.	Garantiza una fila por caso.

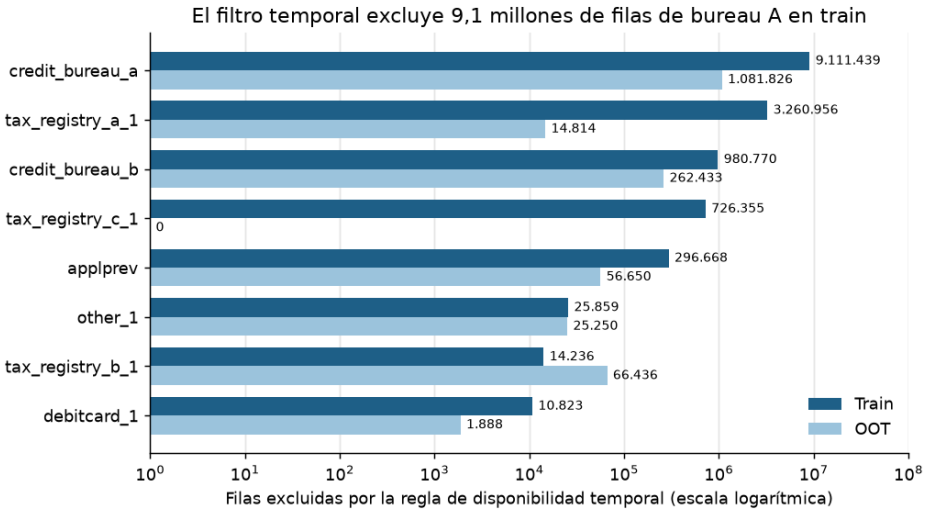


Figura 7. Filas excluidas por la regla de disponibilidad temporal, por familia, en entrenamiento y OOT (escala logarítmica).

3.3 Datos de construcción

Variables agregadas y derivadas. Los nombres siguen la forma <fuente>__<variable>__<agregación>__<ventana>, en minúsculas y con ventana all (todo el historial hasta la decisión). Los tipos de característica son: conteo, mínimo, máximo, media y suma; proporción de una categoría aprobada; número de categorías distintas; recencia en días; atributo de la persona principal; edad en años cumplidos a la decisión; y cobertura (número de registros y presencia de la fuente). El catálogo completo tiene 124 filas, con nombre, rol, tipo lógico, fuente, agregación, ventana y regla temporal.

Contribución por familia. Figura 8 separa predictores y columnas de cobertura por familia. Solo applprev y person aportan predictores.

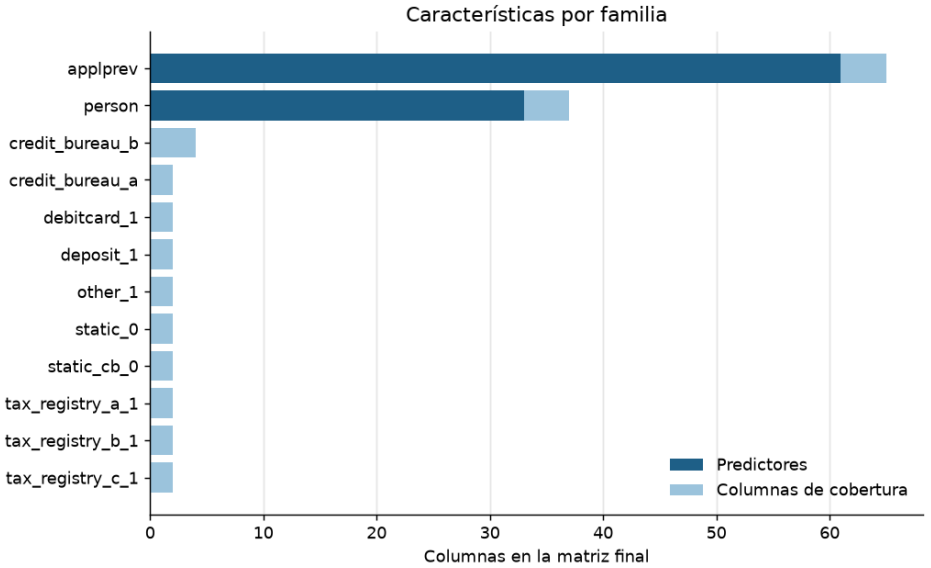


Figura 8. Columnas de la matriz final por familia: predictores y columnas de cobertura.

Prevención de fuga de información. Se aplican cuatro medidas:

1. Filtro temporal antes de agregar: cada fila o valor se compara con date_decision de su caso, y un hijo solo se usa si su padre es válido.
2. Sin aprendizaje fuera de entrenamiento: el preprocesador y las vistas exigen WEEK_NUM < 74 al ajustarse, y transformar OOT o prueba no cambia su estado.
3. Filtro empírico de fuga: de 102 características de solicitudes y personas, las 94 numéricas o booleanas tienen un Gini univariado máximo de 0,184 en valor absoluto, sin ninguna bandera. No garantiza ausencia de fugas moderadas.
4. Exclusiones registradas por regla y familia (Tabla 14). Algunas filas carecen de ancla o de padre válido y no son exclusivamente fechas futuras.

Tabla 14. Filas descartadas o valores anulados por la regla temporal.

Regla	Familia	Entrenamiento	OOT
Solicitud creada después de la decisión	applprev	117 977	22 063
Solicitud sin fecha de creación	applprev	65	1
Hijo de solicitud con padre inválido	applprev	178 626	34 586
Fecha de último pago posterior, anulada	applprev	35 089	6 595
Inicio de empleo posterior, anulado	person	312	4

Regla	Familia	Entrenamiento	OOT
Fila de bureau A con ancla posterior	credit_bureau_a	1 583 190	249 695
Fila de bureau A sin ancla	credit_bureau_a	7 528 249	832 131
Hijo de bureau B con padre inválido	credit_bureau_b	913 190	245 050
Registro fiscal A con fecha posterior	tax_registry_a_1	3 260 956	14 814
Registro fiscal C con fecha posterior	tax_registry_c_1	726 355	0
Registro fiscal B con fecha posterior	tax_registry_b_1	14 236	66 436
Fila sin fecha de disponibilidad	other_1	25 859	25 250
Tarjeta de débito con fecha nula	debitcard_1	10 823	1 888

En el conjunto de prueba se descartaron 16 filas: 13 de bureau A, 2 de other_1 y 1 de tax_registry_b_1.

3.4 Integrar datos

Cada familia se agrega por separado y luego se une a la base con un left join 1:1 por case_id. Nunca se unen dos fuentes 1:N entre sí (Tabla 15).

Tabla 15. Relación de cada familia con la base antes y después de agregar.

Familia	Relación con la base	Filas fuente en entrenamiento	Después de agregar
applprev	1:N (profundidades 1 y 2)	6 525 979 + 14 075 487	1 fila por caso
person	1:N (profundidades 1 y 2)	2 973 991 + 1 643 410	1 fila por caso
static_0, static_cb_0	1:1 y 1:0..1	1 526 659 y 1 500 476	1 fila por caso
credit_bureau_a	1:N	15 940 537 (a_1)	1 fila por caso
credit_bureau_b	1:N (profundidades 1 y 2)	85 791 + 1 286 755	1 fila por caso
Productos y registros	1:N y 1:0..1	Entre 51 109 y 3 343 800	1 fila por caso

Validación de cardinalidad. Los controles de la ejecución final comprueban que las 12 familias de cada conjunto usan la misma base, que cada familia aporta exactamente una fila por caso y que la matriz ensamblada conserva el número, el orden y la unicidad de los casos: 1 332 001 × 129 en entrenamiento, 194 658 × 129 en OOT y 10 × 128 en prueba (sin target).

Hallazgo: fuga en la cobertura de productos y registros. En la primera versión los indicadores de productos y registros contaban todas las filas de la fuente sin mirar su fecha. Al medirlo, el 100 % de las filas de tax_registry_a_1 tenía fecha posterior a la decisión (mediana de +14 días), y también el 21,7 % de tax_registry_c_1. En la versión final la cobertura solo cuenta filas disponibles a la decisión. Una ablación con el mismo modelo, con y sin estos indicadores, midió la Gini Stability en OOT (Tabla 16).

Tabla 16. Gini Stability en OOT según el tratamiento de los indicadores de productos y registros.

Indicadores de productos y registros	Gradient boosting (árboles)	Regresión logística (lineal)
Sin filtro (primera versión, con fuga)	0,4914	0,4503
Solo debitcard_1 y deposit_1 (primera versión)	0,4851	0,4417
Ninguno	0,4861	0,4423
Filtrados por fecha (versión final)	0,4913	0,4523

La ganancia se conserva con el filtro: la aportan tax_registry_b_1 y tax_registry_c_1 ya filtrados y es legítima. Lo que cambió fue el ajuste en entrenamiento (Gini de 0,595 a 0,590), que antes aprovechaba la fuga. Aun filtrados, los registros fiscales se reemplazan unos a otros con el tiempo: la cobertura de tax_registry_b_1 pasa de 1,8 % en entrenamiento a 64,7 % en OOT, y la de tax_registry_c_1 de 30,3 % a 0,0 %. Es deriva de disponibilidad de la fuente y no fuga, y la fase de modelado debe vigilar su estabilidad semanal.

3.5 Formatear datos

La matriz ensamblada pasa por dos vistas, ajustadas solo con entrenamiento y con las mismas filas y el mismo orden de casos (Tabla 17, Figura 9). Las columnas de control (case_id, WEEK_NUM, date_decision, MONTH y target, este último solo en entrenamiento y OOT) preceden a las características en ambas vistas. Los tipos y el orden de las características son iguales entre conjuntos, con la excepción esperada de target en prueba.

Tabla 17. Vistas de la matriz final.

Vista	Numéricas	Categóricas	Nulos	Predictores
Lineal	Imputadas con la mediana de entrenamiento, escaladas, con indicador de ausencia	One-hot sobre vocabulario congelado, más __missing__ y __UNKNOWN__	Ninguno	234
Árboles	Decimales con sus nulos	Enumeración congelada con __UNKNOWN__	Nativos	114

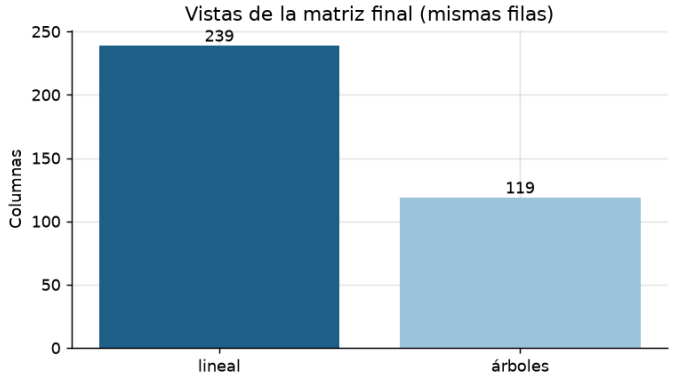


Figura 9. Columnas totales de cada vista en entrenamiento: predictores más cinco columnas de control, con las mismas filas.

Columnas constantes. Una característica con un solo valor en entrenamiento sale de ambas vistas (10, entre ellas las de tax_registry_a_1, other_1 y persontype). En la vista lineal sale además toda salida constante en entrenamiento (43 indicadores de ausencia o niveles one-hot que entrenamiento nunca vio). Una categoría nueva en OOT o prueba queda en la vista lineal con todos sus niveles conocidos en cero, sin ampliar el vocabulario.

Hallazgos resueltos en el cierre. Las columnas constantes se descartan y se registran; una función obsoleta de concatenación se reemplazó por otra que exige la misma altura; la cobertura de productos y registros se filtra por fecha; y los tres conjuntos se publican como unidad, de modo que un fallo tardío borra lo escrito.

Resultado de la fase. La reconstrucción desde cero tardó 101,7 s: reconstruyó las 36 piezas de agregados, las auditó, ensambló la matriz, ajustó las vistas con entrenamiento y pasó 29 de 29 controles de validación final, incluidos tres cotejos contra las matrices publicadas (entrenamiento, OOT y prueba). El comando figura en el Anexo A.

4 Conclusiones de las fases 1 a 3

Las fases 1 a 3 dejaron definidos los objetivos y la métrica, caracterizados los datos y construida una matriz de modelado temporalmente consistente. Los hallazgos principales son:

- La base tiene 1 526 659 casos y un desbalance de 3,14 % de positivos, y la tasa semanal de incumplimiento varía entre 1,77 % y 5,21 %.
- Un join directo de las fuentes sin agregar multiplicaría las filas hasta 123,43 veces, por lo que cada familia se filtra y agrega por separado.
- Solo las solicitudes previas y las personas aportan predictores (94); las otras 10 familias aportan 30 columnas de cobertura.
- Se detectó y corrigió una fuga en los indicadores de productos y registros; la ganancia de la ablación se mantiene con el filtro.
- Las columnas de bureau, registros fiscales y productos quedan bloqueadas como predictores hasta contar con evidencia de disponibilidad al decidir.

Tabla 18 relaciona cada par ON/OM con lo que las fases 2 y 3 encontraron o habilitaron y con lo que sigue pendiente.

Tabla 18. Hallazgos de las fases 2 y 3 por objetivo y pendientes para el modelado.

ON / OM	Qué encontraron o habilitaron las fases 2 y 3	Pendiente
ON1 / OM1	Matriz con una fila por caso: 1 332 001 casos de entrenamiento y 194 658 de OOT, con 124 características y dos vistas (lineal y árboles).	Entrenar modelos y calcular el Gini/AUC global en OOT.
ON2 / OM2	Corte en la semana 74, métrica Gini Stability implementada y probada con datos sintéticos, y filtro temporal en todas las fuentes con fecha. La ablación de 3.4 midió Gini Stability OOT de 0,4913 (árboles) y 0,4523 (lineal) como referencia, no como selección.	Medir la Gini Stability de los modelos candidatos y elegir el modelo.
ON3 / OM3	Catálogo de 124 características con fuente, agregación, ventana y regla temporal. Los 94 predictores provienen solo de solicitudes previas y personas.	Calcular el ranking de importancia. Revisar si las familias bloqueadas pueden aportar predictores.
ON4 / OM4	Desbalance caracterizado (3,28 % en entrenamiento y 2,19 % en OOT) y partición que permite evaluar falsos positivos fuera de tiempo.	Optimizar el umbral y medir FPR a recall fijo. El punto de operación sigue por acordar.

ON / OM	Qué encontraron o habilitaron las fases 2 y 3	Pendiente
ON5 / OM5	Variación semanal de la tasa de incumplimiento y deriva de disponibilidad en los registros fiscales como señales a vigilar.	Definir y validar la regla de alerta. El tamaño de la caída y el número de semanas siguen por acordar.

Siguientes pasos

- Fase 4, modelado: entrenar y comparar modelos de clasificación sobre las dos vistas, con ajuste solo en semanas menores que 74.
- Fase 5, evaluación: medir Gini Stability, Gini/AUC global, Gini semanal, PR AUC, log loss y Brier score en OOT, y analizar la estabilidad por semana.
- Fase 6, implementación: construir el prototipo demostrativo y cerrar el informe y la presentación.
- Acordar los supuestos abiertos de OM4 y OM5 y vigilar la estabilidad semanal de los registros fiscales.

Anexo A Reproducibilidad

Los comandos se ejecutan desde la raíz del repositorio. La preparación completa se reproduce con un solo comando; las etapas de comprensión de datos se ejecutan por separado.

Preparación de datos (fase 3).

```
POLARS_MAX_THREADS=1 uv run -m dm_credit.preparation.build --config
configs/preparation.json --from-scratch
```

Comprensión de datos (fase 2).

Tabla 19. Comandos de las etapas de comprensión de datos.

Etapa	Comando
Catálogo de variables	uv run -m dm_credit.variable_catalog
Calidad e integridad	uv run -m dm_credit.profiling, streaming_profiling, streaming_categories, streaming_key_integrity y quality_catalog (cada uno con -m dm_credit.<módulo>)
Objetivo y tiempo	uv run -m dm_credit.target_analysis --out results/target_analysis
Integración y fuga	POLARS_MAX_THREADS=1 uv run -m dm_credit.integration_analysis

Etapa	Comando
Compatibilidad de esquemas	POLARS_MAX_THREADS=1 uv run -m dm_credit.schema_compatibility
Pruebas automáticas	uv run --extra dev pytest -q
Figuras del informe	uv run --with matplotlib python figures/make_phase_figures.py

Los Parquet grandes de entrenamiento de la matriz final no se versionan; se regeneran con el comando de preparación y sus huellas SHA-256 quedan en el manifiesto de la ejecución. Los manifiestos guardan rutas absolutas solo como información; para regenerar hay que usar el comando y no esas rutas.