PROYECTO INTEGRADOR · MINERÍA DE DATOS · CRISP-DM

Mapa del capítulo 03: preparación de datos

Cómo está repartido el trabajo, qué puede avanzar en paralelo, qué depende de qué y en qué estado está cada tarea. El objetivo del capítulo es una tabla maestra con una fila por `case_id`, sin fuga temporal, para train (`WEEK_NUM < 74`), OOT (⩾ 74) y test.

Estado al **13/10/2026**, según el repositorio Hito oficial: **14/11/2026** Decide G1 y G2: **Andre**

46	43	1	2
tareas y compuertas	hecho	parcial	pendiente



CÓMO LEER EL MAPA

Etiquetas y estados

`[P]` Paralelo: se trabaja a la vez que otras tareas [P] `[S]` Secuencial: espera una compuerta o toca algo compartido

`[R]` Restringida: el código va en paralelo, pero la ejecución real va de una en una (memoria)

● **Hecho** está en `main` ● **Parcial** avanzado, falta una parte o una persona ● **Pendiente** no empezó o no hay código

CAMINO CRÍTICO

Cinco etapas separadas por cuatro compuertas

Dentro de cada etapa, las cinco personas trabajan en paralelo sobre archivos propios. Las **compuertas** (G1 a G4) son los únicos puntos donde hay que esperar:

nadie cruza una compuerta hasta que se cierra.



Dónde estamos: G1, G2 y G3 están cerradas, la ejecución real (E4) validó las 36 piezas, y ya existen las tablas maestras (E5) y sus vistas lineal y de árboles (E6). Para cerrar el capítulo (G4) faltan el comando único de reproducción (E7), la consolidación final de validaciones y las revisiones cruzadas del resto del equipo.

AHORA MISMO

Qué está frenando el avance

Comando único de reproducción (E7)

Hoy cada paso tiene su propio comando (E4, E5, E6 y validación). Falta encadenarlos en uno solo, con su manifiesto final.

Responsable: **Nick**

Revisiones cruzadas (F6)

Andre ya revisó bureau. Faltan las revisiones de Nick, Giancarlo, Mathias y Gabriel sobre un frente ajeno.

Responsables: **Nick, Giancarlo, Mathias y Gabriel**

Tres arreglos menores

Columnas constantes en el preprocesador, una forma obsoleta de `pl.concat` en las vistas y claves repetidas en bureau. Ninguno afecta los resultados actuales.

Responsables: **Gabriel, Giancarlo y Mathias**

Hallazgo para el modelado

La cobertura de los registros fiscales cambia mucho entre periodos (por ejemplo, 36 % en train y 0 % en OOT). Sus indicadores amenazan la estabilidad que mide Gini Stability.

Para el capítulo 04: **todo el equipo**

REPARTO

Quién hace qué en cada etapa

Cada fila es una persona; cada columna, una etapa. Lo que está en la **misma columna** se hace en paralelo. Los recuadros punteados son trabajo extra que Andre hizo fuera de su asignación.

PERSONA	PROPUESTAS A1 a A7	SELECCIÓN DE COLUMNAS B1 a B6	CONSTRUCCIÓN C1 a C8 y D1 a D7	EJECUCIÓN REAL E1 a E7	VALIDACIÓN Y CIERRE F1 a F7
P1 · Nick Contratos, partición, ensamblado y cierre	A1 A2	B1 B2	D6	E1 E2 G3 E4 E5 E7	F2 F3 F5 F6 G4
P2 · Giancarlo Base y profundidad 0, ventana, vistas, informe de fuga	A3 A7	B3	C1 C8 D7	E3 E4	F1 F4 F6 F7 G4
P3 · Andre Solicitudes y personas, coerción y extremos; decide G1 y G2	A4 G1	B4 G2	C2 C3 C8 D4 D5 Lector por shards Contratos y manifiesto Despacho por familia Filtro de fuga	E3 E4	F1 F4 F6 F7 G4
P4 · Mathias Bureau de crédito	A5	B5	C4 C5 C8	E3 E4	F1 F4 F6 F7 G4
P5 · Gabriel Productos, registros fiscales y preprocesador	A6	B6	C6 C7 C8 D1 D2 D3	E3 E4 E6	F1 F4 F6 F7 G4

BACKLOG COMPLETO

Todas las tareas, con dependencias y estado

La columna **Depende de** dice qué tiene que estar listo antes.

ID	TIPO	RESPONSABLE	TRABAJO	DEPENDE DE	ESTADO
Épica A · Contratos y esqueleto compartido					
A1	[P]	Nick	Traducir los contratos de los capítulos 02 y 03 a invariantes ejecutables	—	● Hecho
A2	[P]	Nick	Diseñar interfaces de familia, artefacto, manifiesto y ensamblado	—	● Hecho
A3	[P]	Giancarlo	Catálogo inicial de static_0 y static_cb_0	—	● Hecho
A4	[P]	Andre	Agregaciones de solicitudes y personas; relación de profundidad 2	—	● Hecho
A5	[P] [R]	Mathias	Estrategia de streaming y checkpoints para bureau	—	● Hecho
A6	[P]	Gabriel	Política de faltantes, categorías, coerción y nombres	—	● Hecho
A7	[P]	Giancarlo	Política común de ventana retrospectiva	—	● Hecho
G1	[S]	Andre	Congelar interfaces, nombres, manifiesto, errores, ventana y propiedad de archivos Decidida por Andre el 12/10	A1 a A7	● Hecho
Épica B · Selección y partición					
B1	[P]	Nick	Partición inmutable train/OOT con corte 74 y test separado	G1	● Hecho
B2	[P]	Nick	Validación central de columnas reservadas	G1	● Hecho
B3	[P]	Giancarlo	Columnas permitidas y excluidas de profundidad 0	G1	● Hecho

ID	TIPO	RESPONSABLE	TRABAJO	DEPENDE DE	ESTADO
B4	[P]	Andre	Columnas permitidas y excluidas de solicitudes y personas	G1	● Hecho
B5	[P]	Mathias	Columnas permitidas y excluidas de bureau	G1	● Hecho
B6	[P]	Gabriel	Columnas permitidas y excluidas de productos y registros	G1	● Hecho
G2	[S]	Andre	Aprobar columnas y reglas temporales Cerrada para un primer corte conservador: solo applprev y person aportan predictores; profundidad 0, bureau y productos quedan con 0 aprobados (ampliación §6)	B1 a B6	● Hecho
Épica C · Agregadores por familia					
C1	[P]	Giancarlo	Adaptador de base, static_0 y static_cb_0 Aplica G2: construye solo cobertura, sin predictores aprobados	G1; G2	● Hecho
C2	[P]	Andre	Adaptador de applprev_1 y applprev_2 (padre válido antes que hijo) Una fila por caso de la base; ensamblado real de OOT sin cobertura nula	G1; G2	● Hecho
C3	[P]	Andre	Adaptador de person_1 y person_2	G1; G2	● Hecho
C4	[P] [R]	Mathias	Adaptador streaming de credit_bureau_a_1 y a_2 Ejecución real validada en E4; a_2 se omite sin ancla aprobada	G1; G2	● Hecho
C5	[P] [R]	Mathias	Adaptador de credit_bureau_b_1 y b_2 Ejecución real validada en E4	G1; G2	● Hecho
C6	[P]	Gabriel	Adaptador de debitcard_1, deposit_1 y other_1 Solo cobertura (G2 no aprobó predictores); verificado con los Parquet reales	G1; G2	● Hecho
C7	[P] [R]	Gabriel	Adaptador streaming de tax_registry a, b y c Solo cobertura (G2 no aprobó predictores); verificado con los Parquet reales	G1; G2	● Hecho

ID	TIPO	RESPONSABLE	TRABAJO	DEPENDE DE	ESTADO
C8	[P]	Giancarlo, Andre, Mathias, Gabriel	Catálogo de características por familia Catálogo consolidado: 124 características (94 predictores, 30 de cobertura)	C1 a C7	● Hecho
Épica D · Limpieza y formato					
D1	[P]	Gabriel	Preprocesador que solo se ajusta con train	G1	● Hecho
D2	[P]	Gabriel	Política de faltantes con indicadores de ausencia	G1; C1 a C7	● Hecho
D3	[P]	Gabriel	Categorías raras y desconocidas (__UNKNOWN__)	G1	● Hecho
D4	[P]	Andre	Coerción estricta de tipos	G1	● Hecho
D5	[P]	Andre	Política de extremos ajustada en train	G1	● Hecho
D6	[P]	Nick	Esquema final ordenado e idéntico en train, OOT y test	G1	● Hecho
D7	[P]	Giancarlo	Vistas de la matriz: lineal y de árboles	G1; D1 a D3	● Hecho
Épica E · Integración y tabla maestra					
E1	[P]	Nick	Ensamblador que solo acepta agregados con case_id único	G1	● Hecho
E2	[P]	Nick	Validaciones después de cada join	G1	● Hecho
E3	[P]	Giancarlo, Andre, Mathias, Gabriel	Artefactos pequeños de cada adaptador para el ensamblador Artefactos sintéticos de las cuatro familias	C1 a C7 parciales	● Hecho
G3	[S]	Nick	Integración sintética de los adaptadores y el preprocesador Cerrada por Andre: pipeline completo sintético, contratos congelados	E1 a E3; D1 a D7	● Hecho

ID	TIPO	RESPONSABLE	TRABAJO	DEPENDE DE	ESTADO
E4	[S] [R]	Todos	Generar agregados reales, de una familia a la vez 36 piezas reconstruidas en serie por Andre (55,6 s; pico 2,1 GB); auditoría 36/36	G2; G3; C1 a C7	Hecho
E5	[S] [R]	Nick	Ensamblar las tablas maestras Tablas maestras por Andre: 1 332 001 / 194 658 / 10 filas, 124 características	E4	Hecho
E6	[S] [R]	Gabriel	Ajustar el preprocesador con train y transformar OOT y test Vistas por Andre: lineal 303 predictores sin nulos; árboles 124	E5	Hecho
E7	[S]	Nick	Manifiesto final y comando único de reproducción	E6	Pendiente
Épica F · Validación, documentación y cierre					
F1	[P]	Giancarlo, Andre, Mathias, Gabriel	Pruebas de cada adaptador y catálogo Auditoría y pruebas nuevas; 1 fallo esperado en bureau	C1 a C8	Hecho
F2	[P]	Nick	Pruebas end-to-end sintéticas del pipeline Cubierto por la prueba de integración de G3	G3	Hecho
F3	[S]	Nick	Validaciones sobre los artefactos reales 26/26 controles sobre las piezas de E4	E7	Hecho
F4	[P]	Giancarlo, Andre, Mathias, Gabriel	Redactar los resultados de cada fuente results/preparation/family_results.csv	E4	Hecho
F5	[S]	Nick	Consolidar development/03-preparacion-datos.md Capítulo 03 redactado sin marcadores pendientes	F3; F4; F7	Hecho
F6	[S]	Todos	Revisión cruzada: cada persona revisa un frente ajeno Hecha la revisión de Andre a bureau; faltan las demás	F5	Parcial
F7	[S]	Giancarlo, Andre, Mathias, Gabriel	Informe de fuga temporal por familia Informe de fuga consolidado de las 12 familias	B3 a B6; E4	Hecho

ID	TIPO	RESPONSABLE	TRABAJO	DEPENDE DE	ESTADO
G4	[S]	Todos	Cierre del capítulo 03	F1 a F7	● Pendiente

CALENDARIO

Fechas propuestas en el backlog

Quedan 32 días hasta el hito. El tramo más largo es la ejecución real (E4), que va en cola de a una familia por vez, con `credit_bureau_a_2` al final.

12/10	**A1 a A7 y G1**	Hecho antes de lo previsto (estaba para el 15 y 16/10)
13/10	**Hoy**	G3, E4, E5 y E6 cerradas; falta E7, F6 y G4
23/10	**B, C en esqueleto, D, E1 a E3, F1 y F2**	Todo en paralelo
26/10	**G2 (fecha prevista)**	Ya cerrada el 13/10
30/10	**C1 a C8 funcionales**	Adaptadores ya listos el 13/10; faltan catálogos y ejecución real de bureau
02/11	**G3**	Integración sintética
03 a 06/11	**E4**	Ejecución real en cola, bureau A al final
09 a 11/11	**E5, E6 y E7**	Ensamblado, preprocesado y manifiesto
12/11	**F3, F4 y F7**	Validación y redacción
13/11	**F5, F6 y G4**	Cierre
14/11	**Hito oficial**	Entrega del capítulo de preparación

Fuentes: `context/03-preparacion-datos-backlog.md`, las decisiones de G1 y G2 en `context/`, y el código y los resultados en `main` (último commit revisado: `df4af28`).

P1 = Nick · P2 = Giancarlo · P3 = Andre · P4 = Mathias · P5 = Gabriel.