PROYECTO INTEGRADOR · MINERÍA DE DATOS · CRISP-DM

Mapa del capítulo 03: preparación de datos

Cómo está repartido el trabajo, qué puede avanzar en paralelo, qué depende de qué y en qué estado está cada tarea. El objetivo del capítulo es una tabla maestra con una fila por `case_id`, sin fuga temporal, para train (`WEEK_NUM < 74`), OOT (⩾ 74) y test.

Estado al **13/10/2026**, según el repositorio Hito oficial: **14/11/2026** Decide G1 y G2: **Andre**

46	46	0	0
tareas y compuertas	hecho	parcial	pendiente

CÓMO LEER EL MAPA

Etiquetas y estados

`[P]` Paralelo: se trabaja a la vez que otras tareas [P] `[S]` Secuencial: espera una compuerta o toca algo compartido

`[R]` Restringida: el código va en paralelo, pero la ejecución real va de una en una (memoria)

● **Hecho** está en `main` ● **Parcial** avanzado, falta una parte o una persona ● **Pendiente** no empezó o no hay código

CAMINO CRÍTICO

Cinco etapas separadas por cuatro compuertas

Dentro de cada etapa, las cinco personas trabajan en paralelo sobre archivos propios. Las **compuertas** (G1 a G4) son los únicos puntos donde hay que esperar:

nadie cruza una compuerta hasta que se cierra.

A1 a A7
Propuestas
7 de 7 hechas ·
● Hecho

G1
12/10

B1 a B6
Selección de columnas
6 de 6 hechas ·
● Hecho

G2
13/10

C1 a C8 y D1 a D7
Construcción
15 de 15 hechas ·
● Hecho

G3
02/11

E1 a E7
Ejecución real
7 de 7 hechas ·
● Hecho

F1 a F7
Validación y cierre
7 de 7 hechas ·
● Hecho

G4
13/11

Capítulo cerrado: las cuatro compuertas están cerradas. Un solo comando reconstruye todo desde los Parquet originales en unos 100 s, pasa 29 de 29 controles y la suite completa (706 pruebas) pasa sin fallos esperados. Al consolidar F7 apareció una fuga en la cobertura de registros fiscales; se corrigió antes de cerrar (`products-v2`).

DESPUÉS DEL CIERRE

Qué se resolvió en G4 y qué pasa al capítulo 04

Fuga en la cobertura de productos (resuelta)

El 100 % de las filas de `tax_registry_a_1` tenía fecha posterior a la decisión. Desde `products-v2` solo cuentan filas disponibles a la decisión; la ablación confirma que la ganancia restante es legítima (Gini Stability 0,4913 frente a 0,4861).

Resuelto por: **Andre** (F7)

Hallazgos de F1 y F6 (resueltos)

Claves repetidas en bureau, columnas constantes, `pl.concat` obsoleto, publicación de E5, parámetros de E7 y validación de claves en productos.

Resueltos por: **Mathias** (bureau) y **Andre**

Deriva de registros fiscales

Aun filtrada, la cobertura cambia entre periodos: `tax_registry_b_1` pasa de 1,8 % a 64,7 % y `_c_1` de 30,3 % a 0 %. No es fuga, sino disponibilidad de la fuente.

Para el capítulo 04: **vigilar el Gini semanal**

Riesgos aceptados

Las coberturas de profundidad 0 no tienen fecha propia (fila estática de la solicitud) y los informes guardan rutas absolutas en campos informativos.

Documentados en: **G4 — cierre**

REPARTO

Quién hace qué en cada etapa

Cada fila es una persona; cada columna, una etapa. Lo que está en la **misma columna** se hace en paralelo. Los recuadros punteados son trabajo extra que Andre hizo fuera de su asignación.

PERSONA	PROPUESTAS A1 a A7	SELECCIÓN DE COLUMNAS B1 a B6	CONSTRUCCIÓN C1 a C8 y D1 a D7	EJECUCIÓN REAL E1 a E7	VALIDACIÓN Y CIERRE F1 a F7
P1 · Nick Contratos, partición, ensamblado y cierre	A1 A2	B1 B2	D6	E1 E2 G3 E4 E5 E7	F2 F3 F5 F6 G4
P2 · Giancarlo Base y profundidad 0, ventana, vistas, informe de fuga	A3 A7	B3	C1 C8 D7	E3 E4	F1 F4 F6 F7 G4
P3 · Andre Solicitudes y personas, coerción y extremos; decide G1 y G2	A4 G1	B4 G2	C2 C3 C8 D4 D5 Lector por shards Contratos y manifiesto Despacho por familia Filtro de fuga	E3 E4	F1 F4 F6 F7 G4
P4 · Mathias Bureau de crédito	A5	B5	C4 C5 C8	E3 E4	F1 F4 F6 F7 G4
P5 · Gabriel Productos, registros fiscales y preprocesador	A6	B6	C6 C7 C8 D1 D2 D3	E3 E4 E6	F1 F4 F6 F7 G4

BACKLOG COMPLETO

Todas las tareas, con dependencias y estado

La columna **Depende de** dice qué tiene que estar listo antes.

ID	TIPO	RESPONSABLE	TRABAJO	DEPENDE DE	ESTADO
Épica A · Contratos y esqueleto compartido					
A1	[P]	Nick	Traducir los contratos de los capítulos 02 y 03 a invariantes ejecutables	—	● Hecho
A2	[P]	Nick	Diseñar interfaces de familia, artefacto, manifiesto y ensamblado	—	● Hecho
A3	[P]	Giancarlo	Catálogo inicial de static_0 y static_cb_0	—	● Hecho
A4	[P]	Andre	Agregaciones de solicitudes y personas; relación de profundidad 2	—	● Hecho
A5	[P] [R]	Mathias	Estrategia de streaming y checkpoints para bureau	—	● Hecho
A6	[P]	Gabriel	Política de faltantes, categorías, coerción y nombres	—	● Hecho
A7	[P]	Giancarlo	Política común de ventana retrospectiva	—	● Hecho
G1	[S]	Andre	Congelar interfaces, nombres, manifiesto, errores, ventana y propiedad de archivos Decidida por Andre el 12/10	A1 a A7	● Hecho
Épica B · Selección y partición					
B1	[P]	Nick	Partición inmutable train/OOT con corte 74 y test separado	G1	● Hecho
B2	[P]	Nick	Validación central de columnas reservadas	G1	● Hecho
B3	[P]	Giancarlo	Columnas permitidas y excluidas de profundidad 0	G1	● Hecho

ID	TIPO	RESPONSABLE	TRABAJO	DEPENDE DE	ESTADO
B4	[P]	Andre	Columnas permitidas y excluidas de solicitudes y personas	G1	● Hecho
B5	[P]	Mathias	Columnas permitidas y excluidas de bureau	G1	● Hecho
B6	[P]	Gabriel	Columnas permitidas y excluidas de productos y registros	G1	● Hecho
G2	[S]	Andre	Aprobar columnas y reglas temporales Cerrada para un primer corte conservador: solo applprev y person aportan predictores; profundidad 0, bureau y productos quedan con 0 aprobados (ampliación §6)	B1 a B6	● Hecho
Épica C · Agregadores por familia					
C1	[P]	Giancarlo	Adaptador de base, static_0 y static_cb_0 Aplica G2: construye solo cobertura, sin predictores aprobados	G1; G2	● Hecho
C2	[P]	Andre	Adaptador de applprev_1 y applprev_2 (padre válido antes que hijo) Una fila por caso de la base; ensamblado real de OOT sin cobertura nula	G1; G2	● Hecho
C3	[P]	Andre	Adaptador de person_1 y person_2	G1; G2	● Hecho
C4	[P] [R]	Mathias	Adaptador streaming de credit_bureau_a_1 y a_2 Ejecución real validada en E4; a_2 se omite sin ancla aprobada	G1; G2	● Hecho
C5	[P] [R]	Mathias	Adaptador de credit_bureau_b_1 y b_2 Ejecución real validada en E4	G1; G2	● Hecho
C6	[P]	Gabriel	Adaptador de debitcard_1, deposit_1 y other_1 Solo cobertura (G2 no aprobó predictores); verificado con los Parquet reales	G1; G2	● Hecho
C7	[P] [R]	Gabriel	Adaptador streaming de tax_registry a, b y c Solo cobertura (G2 no aprobó predictores); verificado con los Parquet reales	G1; G2	● Hecho

ID	TIPO	RESPONSABLE	TRABAJO	DEPENDE DE	ESTADO
C8	[P]	Giancarlo, Andre, Mathias, Gabriel	Catálogo de características por familia Catálogo consolidado: 124 características (94 predictores, 30 de cobertura)	C1 a C7	● Hecho
Épica D · Limpieza y formato					
D1	[P]	Gabriel	Preprocesador que solo se ajusta con train	G1	● Hecho
D2	[P]	Gabriel	Política de faltantes con indicadores de ausencia	G1; C1 a C7	● Hecho
D3	[P]	Gabriel	Categorías raras y desconocidas (__UNKNOWN__)	G1	● Hecho
D4	[P]	Andre	Coerción estricta de tipos	G1	● Hecho
D5	[P]	Andre	Política de extremos ajustada en train	G1	● Hecho
D6	[P]	Nick	Esquema final ordenado e idéntico en train, OOT y test	G1	● Hecho
D7	[P]	Giancarlo	Vistas de la matriz: lineal y de árboles	G1; D1 a D3	● Hecho
Épica E · Integración y tabla maestra					
E1	[P]	Nick	Ensamblador que solo acepta agregados con case_id único	G1	● Hecho
E2	[P]	Nick	Validaciones después de cada join	G1	● Hecho
E3	[P]	Giancarlo, Andre, Mathias, Gabriel	Artefactos pequeños de cada adaptador para el ensamblador Artefactos sintéticos de las cuatro familias	C1 a C7 parciales	● Hecho
G3	[S]	Nick	Integración sintética de los adaptadores y el preprocesador Cerrada por Andre: pipeline completo sintético, contratos congelados	E1 a E3; D1 a D7	● Hecho

ID	TIPO	RESPONSABLE	TRABAJO	DEPENDE DE	ESTADO
E4	[S] [R]	Todos	Generar agregados reales, de una familia a la vez 36 piezas reconstruidas en serie por Andre (55,6 s; pico 2,1 GB); auditoría 36/36	G2; G3; C1 a C7	● Hecho
E5	[S] [R]	Nick	Ensamblar las tablas maestras Tablas maestras por Andre: 1 332 001 / 194 658 / 10 filas, 124 características	E4	● Hecho
E6	[S] [R]	Gabriel	Ajustar el preprocesador con train y transformar OOT y test Vistas por Andre: lineal 234 predictores sin nulos; árboles 114; constantes descartadas	E5	● Hecho
E7	[S]	Nick	Manifiesto final y comando único de reproducción Un comando desde cero: 7 pasos, unos 100 s, salidas reproducibles	E6	● Hecho
Épica F · Validación, documentación y cierre					
F1	[P]	Giancarlo, Andre, Mathias, Gabriel	Pruebas de cada adaptador y catálogo Auditoría y pruebas nuevas; el fallo de bureau lo corrigió Mathias	C1 a C8	● Hecho
F2	[P]	Nick	Pruebas end-to-end sintéticas del pipeline Cubierto por la prueba de integración de G3	G3	● Hecho
F3	[S]	Nick	Validaciones sobre los artefactos reales 29/29 controles tras E7 desde cero, incluidos los cotejos de E5	E7	● Hecho
F4	[P]	Giancarlo, Andre, Mathias, Gabriel	Redactar los resultados de cada fuente family_results.csv con comando, informe y fecha por fuente (Mathias)	E4	● Hecho
F5	[S]	Nick	Consolidar development/03-preparacion-datos.md Capítulo 03 consolidado por Nick y actualizado en el cierre	F3; F4; F7	● Hecho
F6	[S]	Todos	Revisión cruzada: cada persona revisa un frente ajeno Revisión de Andre a bureau y revisiones técnicas de Nick; hallazgos resueltos en G4	F5	● Hecho

ID	TIPO	RESPONSABLE	TRABAJO	DEPENDE DE	ESTADO
F7	[S]	Giancarlo, Andre, Mathias, Gabriel	Informe de fuga temporal por familia 12 familias; detectó la fuga de registros fiscales, corregida con products-v2	B3 a B6; E4	● Hecho
G4	[S]	Todos	Cierre del capítulo 03 Cerrada por Andre: definición de terminado 15/15, suite y git diff --check limpios	F1 a F7	● Hecho

CALENDARIO

Fechas propuestas en el backlog

El capítulo se cerró el 13/10, un mes antes del hito. Las fechas de abajo son las que proponía el backlog.

12/10	**A1 a A7 y G1**	Hecho antes de lo previsto (estaba para el 15 y 16/10)
13/10	**Hoy**	Capítulo 03 cerrado: G3, E4 a E7, F1 a F7 y G4
23/10	**B, C en esqueleto, D, E1 a E3, F1 y F2**	Todo en paralelo
26/10	**G2 (fecha prevista)**	Ya cerrada el 13/10
30/10	**C1 a C8 funcionales**	Adaptadores ya listos el 13/10; faltan catálogos y ejecución real de bureau
02/11	**G3**	Integración sintética
03 a 06/11	**E4**	Ejecución real en cola, bureau A al final
09 a 11/11	**E5, E6 y E7**	Ensamblado, preprocesado y manifiesto
12/11	**F3, F4 y F7**	Validación y redacción
13/11	**F5, F6 y G4**	Cierre
14/11	**Hito oficial**	Entrega del capítulo de preparación

Fuentes: `context/03-preparacion-datos-backlog.md`, el cierre en `context/03-preparacion-G4-cierre.md`, las decisiones de G1 y G2 en `context/`, y el código y los resultados en `main` (último commit revisado: `70b375f`).

P1 = Nick · P2 = Giancarlo · P3 = Andre · P4 = Mathias · P5 = Gabriel.